

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN, ĐHQG-TPHCM
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG



BÁO CÁO ĐỒ ÁN MÔN HỌC
ĐỀ TÀI: XÂY DỰNG HỆ THỐNG FEDERATED
LEARNING TRÊN NỀN TẢNG FEDML

Môn học: NT533.Q12 – Hệ tính toán phân bố

Giảng viên hướng dẫn: ThS. Lê Anh Tuấn

Thực hiện bởi nhóm 12, bao gồm:

1. Đỗ Gia Hân	23520425	Trưởng nhóm
2. Bùi Nguyễn Tường Vân	23521768	Thành viên
3. Trần Ngọc Thuý Vy	23521837	Thành viên

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU TỔNG QUAN.....	3
CHƯƠNG 2. CÁC CÔNG NGHỆ LIÊN QUAN	4
2.1. Federated Learning sử dụng nền tảng FedML.....	4
2.1.1. Giới thiệu.....	4
2.1.2. Các chức năng chính	4
2.1.3. Cơ chế hoạt động.....	5
2.1.4. Ưu điểm và hạn chế.....	5
2.2. Microsoft Azure	5
2.2.1. Giới thiệu.....	5
2.2.2. Các chức năng chính	6
2.2.3. Cơ chế hoạt động.....	6
2.2.4. Ưu điểm và hạn chế.....	7
2.3. Wandb	7
2.3.1. Giới thiệu.....	7
2.3.2. Các chức năng chính	7
2.3.3. Cơ chế hoạt động.....	8
2.3.4. Ưu điểm và hạn chế.....	9
CHƯƠNG 3. TRIỂN KHAI	10
3.1. Kiến trúc hệ thống.....	10
3.2. Cài đặt	12
3.3. Cấu hình và triển khai	12
3.4. Triển khai các kịch bản thử nghiệm.....	14
CHƯƠNG 4. KẾT QUẢ CÁC KỊCH BẢN THỬ NGHIỆM.....	16

4.1. Kết quả mô hình Logistic Regression (LR) trên MNIST (1 server – 2 clients):	16
4.2. Kết quả mô hình CNN trên MNIST (1 server- 4 clients):	17
CHƯƠNG 5. KẾT LUẬN.....	18
5.1. Kết quả đạt được:	18
5.2. Hạn chế và khó khăn:	18
5.3. Hướng phát triển:	18
TÀI LIỆU THAM KHẢO	19

CHƯƠNG 1. GIỚI THIỆU TỔNG QUAN

Trong bối cảnh dữ liệu số ngày càng gia tăng, việc huấn luyện các mô hình học máy (ML) đòi hỏi lượng dữ liệu lớn và chất lượng cao. Tuy nhiên, việc tập trung dữ liệu về một máy chủ duy nhất thường gặp khó khăn do các quy định khắt khe về quyền riêng tư và lo ngại về bảo mật của các tổ chức. Federated Learning (Học liên kết) ra đời như một phương pháp học máy phân tán cho phép huấn luyện mô hình trên dữ liệu tại chỗ mà không cần di chuyển dữ liệu gốc, giúp đảm bảo quyền riêng tư và tuân thủ pháp lý.

FedML là một nền tảng mã nguồn mở chuyên biệt hỗ trợ xây dựng và triển khai hệ thống Federated Learning trên nhiều môi trường từ thiết bị IoT đến hạ tầng đám mây. Việc sử dụng FedML kết hợp với hạ tầng Microsoft Azure cung cấp khả năng điều phối các nút huấn luyện phân tán một cách an toàn và hiệu quả trên thực tế.

Mục tiêu chính của đề tài là nghiên cứu và xây dựng thành công một hệ thống Federated Learning thực tế sử dụng framework FedML trên hạ tầng điện toán đám mây. Các mục tiêu cụ thể bao gồm:

- Xây dựng kiến trúc hệ thống: Thiết lập mô hình Client-Server phân tán, trong đó các nút tính toán (Server và Client) hoạt động độc lập trên các máy ảo (Virtual Machines) của Microsoft Azure để mô phỏng môi trường thực tế.
- Hiện thực hóa quy trình huấn luyện liên kết: Triển khai quy trình từ khởi tạo mô hình toàn cục (Global model), phân phối đến các máy trạm, huấn luyện cục bộ (Local training) và tổng hợp tham số bằng thuật toán FedAvg mà không làm lộ dữ liệu thô.
- Thử nghiệm và đánh giá hiệu năng: Thực hiện huấn luyện các mô hình học máy khác nhau như Logistic Regression (LR) và mạng thần kinh tích chập (CNN) trên tập dữ liệu MNIST để đánh giá độ chính xác và khả năng hội tụ của hệ thống.
- Tối ưu hóa và giám sát: Tích hợp các công cụ giám sát như WandB để theo dõi các chỉ số quan trọng (Test Accuracy, Test Loss) theo thời gian thực, đồng thời đánh giá thời gian thực hiện của các kịch bản khác nhau.

CHƯƠNG 2. CÁC CÔNG NGHỆ LIÊN QUAN

2.1. Federated Learning sử dụng nền tảng FedML

2.1.1. Giới thiệu

Federated Learning là một phương pháp học máy thuộc lĩnh vực hệ thống tính toán phân tán, trong đó quá trình huấn luyện mô hình được thực hiện trên nhiều nút tính toán phân tán khác nhau mà không cần tập trung dữ liệu về một máy chủ trung tâm. Thay vì thu thập và lưu trữ toàn bộ dữ liệu tại một nơi như mô hình học máy truyền thống, Federated Learning cho phép mỗi nút hoặc mỗi thiết bị giữ nguyên dữ liệu cục bộ và chỉ chia sẻ các tham số mô hình sau quá trình huấn luyện. Cách tiếp cận này đặc biệt phù hợp với các hệ thống phân tán quy mô lớn, nơi dữ liệu phân bố rải rác và có yêu cầu cao về bảo mật, quyền riêng tư cũng như tuân thủ các quy định pháp lý về dữ liệu.

Federated Learning được triển khai thông qua nền tảng FedML – một framework mã nguồn mở được thiết kế chuyên biệt cho các hệ thống học máy phân tán và học liên kết. FedML cung cấp một kiến trúc chuẩn hóa cho việc xây dựng, mô phỏng và triển khai Federated Learning trên nhiều môi trường khác nhau, từ máy cá nhân, máy chủ, thiết bị IoT cho đến hạ tầng đám mây. Việc sử dụng FedML giúp đơn giản hóa việc tiếp cận trực tiếp với các mô hình Federated Learning thực tế, thay vì chỉ dừng ở mức lý thuyết.

2.1.2. Các chức năng chính

FedML đảm nhiệm vai trò là framework điều khiển toàn bộ logic Federated Learning. Chức năng quan trọng nhất của FedML là tổ chức và quản lý các node huấn luyện phân tán. Mỗi node trong hệ thống được xem như một client độc lập, sở hữu dữ liệu cục bộ riêng và thực hiện huấn luyện mô hình cục bộ theo kịch bản được định nghĩa sẵn.

FedML còn cung cấp chức năng điều phối quá trình huấn luyện theo mô hình client-server. Framework này cho phép xác định rõ vai trò của server và các client, giúp quá trình huấn luyện phân tán diễn ra đúng trình tự, đúng số vòng và đúng thuật toán tổng hợp.

Một chức năng quan trọng khác của FedML là tích hợp sẵn các thuật toán Federated Learning phổ biến, đặc biệt là Federated Averaging.

Ngoài ra, FedML còn hỗ trợ quản lý luồng dữ liệu và tham số mô hình, đảm bảo

rằng trong suốt quá trình huấn luyện, chỉ các tham số mô hình được trao đổi giữa các node, còn dữ liệu gốc luôn được giữ tại client.

2.1.3. Cơ chế hoạt động

Cơ chế hoạt động của FedML tuân theo quy trình Federated Learning chuẩn nhưng được hiện thực hóa rõ ràng thông qua framework. Trước hết, FedML khởi tạo một mô hình toàn cục tại node server. Mô hình này đóng vai trò là trạng thái ban đầu của hệ thống phân tán và được gửi đến các client tham gia huấn luyện.

Tại mỗi client, FedML kích hoạt quá trình huấn luyện cục bộ dựa trên dữ liệu riêng của client đó. Quá trình này diễn ra song song giữa các client, thể hiện rõ đặc trưng tính toán phân tán và khai thác tính song song của hệ thống. Sau khi hoàn tất huấn luyện cục bộ, mỗi client gửi lại các tham số mô hình đã cập nhật cho server thông qua cơ chế truyền thông do FedML quản lý.

Node server sử dụng các tham số nhận được để thực hiện bước tổng hợp mô hình, thường là trung bình hóa các tham số theo thuật toán FedAvg. Kết quả của bước tổng hợp là một mô hình toàn cục mới, phản ánh tri thức học được từ toàn bộ hệ thống. Mô hình này tiếp tục được FedML phân phối trở lại các client để bắt đầu vòng huấn luyện tiếp theo. Chu trình này lặp lại nhiều vòng cho đến khi mô hình hội tụ hoặc đạt tiêu chí dừng.

2.1.4. Ưu điểm và hạn chế

Federated Learning mang lại nhiều ưu điểm quan trọng trong môi trường tính toán phân tán, đặc biệt là khả năng bảo vệ quyền riêng tư dữ liệu do dữ liệu gốc không rời khỏi nơi lưu trữ. Phương pháp này giúp giảm chi phí truyền dữ liệu, hạn chế nguy cơ rò rỉ thông tin và phù hợp với các hệ thống có dữ liệu nhạy cảm như y tế, tài chính. Tuy nhiên, Federated Learning cũng tồn tại những hạn chế đáng kể, bao gồm độ phức tạp trong việc đồng bộ và tổng hợp mô hình từ các nút có năng lực tính toán và phân bố dữ liệu khác nhau. Ngoài ra, chất lượng mô hình toàn cục có thể bị ảnh hưởng bởi dữ liệu không đồng đều giữa các nút và yêu cầu hạ tầng mạng ổn định để đảm bảo quá trình trao đổi tham số diễn ra hiệu quả.

2.2. Microsoft Azure

2.2.1. Giới thiệu



Hình 1. Logo Microsoft Azure

Microsoft Azure là nền tảng điện toán đám mây cung cấp hạ tầng và dịch vụ toàn diện cho việc xây dựng, triển khai và quản lý các hệ thống tính toán phân tán. Trong lĩnh vực học máy, Azure Machine Learning đóng vai trò là môi trường trung tâm hỗ trợ toàn bộ vòng đời của mô hình, từ huấn luyện, kiểm thử đến triển khai. Khi kết hợp với Federated Learning, Azure cung cấp nền tảng phù hợp để điều phối các nút huấn luyện phân tán một cách hiệu quả và an toàn.

Microsoft Azure được sử dụng như nền tảng hạ tầng đám mây để triển khai hệ thống FedML, đóng vai trò hiện thực hóa môi trường tính toán phân bố trên thực tế. Azure cho phép triển khai các node FedML trên các máy ảo độc lập, mô phỏng các client và server nằm ở những vị trí địa lý hoặc tổ chức khác nhau.

2.2.2. Các chức năng chính

Azure cung cấp tài nguyên tính toán phân tán. Mỗi node FedML, bao gồm server và các client, được triển khai trên các máy ảo Azure riêng biệt. Điều này giúp đảm bảo tính độc lập giữa các node và mô phỏng chính xác kiến trúc phân tán.

Azure cũng đảm nhiệm chức năng quản lý và mở rộng hạ tầng. Khi số lượng client tăng lên, hệ thống có thể dễ dàng mở rộng bằng cách tạo thêm máy ảo mới mà không cần thay đổi kiến trúc tổng thể của đồ án. Bên cạnh đó, Azure cung cấp chức năng kết nối mạng ổn định và bảo mật giữa các node. Các node FedML giao tiếp với nhau thông qua mạng nội bộ hoặc mạng ảo của Azure, đảm bảo việc trao đổi tham số mô hình diễn ra liên tục và an toàn. Điều này giúp quá trình huấn luyện phân tán không bị gián đoạn.

Ngoài ra, Azure còn hỗ trợ giám sát và quản lý tài nguyên, cho phép theo dõi mức sử dụng CPU, bộ nhớ và trạng thái hoạt động của từng node.

2.2.3. Cơ chế hoạt động

Azure đóng vai trò là lớp hạ tầng bên dưới FedML. Trước hết, các máy ảo Azure được cấu hình để chạy các thành phần của FedML, bao gồm một node server và nhiều node client. Mỗi node hoạt động như một tiến trình độc lập trên hạ tầng đám mây.

Khi hệ thống bắt đầu huấn luyện, Azure đảm bảo các node có thể kết nối và trao đổi dữ liệu thông qua mạng ảo. FedML điều phối logic huấn luyện, trong khi Azure chịu trách nhiệm duy trì môi trường thực thi ổn định. Trong mỗi vòng huấn luyện, Azure cho phép các client thực hiện huấn luyện cục bộ song song, sau đó truyền tham số về server một cách đồng bộ.

2.2.4. Ưu điểm và hạn chế

Việc sử dụng Azure trong Federated Learning mang lại ưu điểm lớn về khả năng mở rộng, tính sẵn sàng cao và tích hợp bảo mật mạnh mẽ. Azure hỗ trợ mã hóa dữ liệu, quản lý truy cập và giám sát hệ thống, giúp tăng độ tin cậy cho các mô hình học máy phân tán. Tuy nhiên, việc triển khai Federated Learning trên Azure cũng đòi hỏi kiến thức chuyên sâu về hạ tầng đám mây và có thể phát sinh chi phí đáng kể nếu không được tối ưu hợp lý.

2.3. Wandb

2.3.1. Giới thiệu



Hình 2. Logo Wandb

Weights & Biases (viết tắt là WandB) là một nền tảng **MLOps** giúp theo dõi, quản lý và trực quan hóa toàn bộ vòng đời huấn luyện mô hình Machine Learning / Deep Learning.

WandB thường được dùng trong:

- Nghiên cứu AI
- Huấn luyện mô hình Deep Learning
- Các dự án ML nhóm
- Triển khai và đánh giá mô hình

2.3.2. Các chức năng chính

(1) Theo dõi thí nghiệm (Experiment Tracking)

- Ghi lại loss, accuracy, precision, recall...
- Theo dõi hyperparameters (learning rate, batch size, epoch...)
- So sánh nhiều lần train khác nhau

(2) Visualization & Dashboard

- Biểu đồ training theo thời gian thực
- So sánh các mô hình trên cùng 1 dashboard
- Theo dõi GPU/CPU/RAM usage

(3) Quản lý mô hình & dữ liệu

- Model Registry: lưu trữ phiên bản mô hình
- Lưu checkpoints
- Quản lý dataset & artifacts

(4) Hỗ trợ teamwork

- Chia sẻ kết quả train cho cả nhóm
- Gắn tag, note cho từng experiment
- Phân quyền user trong project

(5) Hyperparameter Tuning (Sweeps)

- Tự động chạy nhiều cấu hình
- Grid search / Random search / Bayesian optimization

2.3.3. Cơ chế hoạt động

(1) Cài WandB: ***pip install wandb***

(2) Đăng nhập: ***wandb login***

(3) Khởi tạo trong code

```
import wandb  
wandb.init(project="my_project")
```

(4) Log dữ liệu khi train

```
wandb.log({  
    "loss": loss,  
    "accuracy": acc }
```

(5) Dữ liệu được gửi lên WandB server

- Hiển thị real-time trên dashboard
- Lưu lại lịch sử training
- WandB hoạt động theo mô hình Client – Server:
- Client: code ML của bạn
- Server: WandB cloud (hoặc self-hosted)

2.3.4. Ưu điểm và hạn chế

Ưu điểm

- Giao diện trực quan, dễ theo dõi
- Hỗ trợ nhiều framework ML phổ biến
- Theo dõi thí nghiệm real-time
- Rất tốt cho làm việc nhóm
- Tối ưu cho nghiên cứu & production ML

Hạn chế

- Cần internet để sync (nếu dùng cloud)
- Có thể phức tạp với người mới
- Gói miễn phí bị giới hạn tài nguyên
- Dự án lớn có thể tốn chi phí

CHƯƠNG 3. TRIỂN KHAI

3.1. Kiến trúc hệ thống

Kiến trúc hệ thống được thiết kế theo mô hình Client-Server phân tán, phân chia thành các lớp chức năng cụ thể để quản lý vòng đời huấn luyện mô hình.

3.1.1. Phân tầng kiến trúc


FedML-core (Low-level APIs): Lớp lõi chịu trách nhiệm quản lý truyền thông hạ tầng, bao gồm các giao thức như gRPC, MPI, và MQTT. Trong báo cáo này, giao thức gRPC được chọn làm backend chính vì khả năng truyền tải trọng số (weights) và gradient dưới dạng tensor nhanh hơn so với các phương thức thông thường.

FedML-API (High-level APIs): Cung cấp các công cụ bậc cao để định nghĩa thuật toán tổng hợp (như FedAvg), quản lý dữ liệu và thiết lập mô hình huấn luyện.


Application Layer: Nơi người dùng định nghĩa các kịch bản cụ thể (ví dụ: Logistic Regression hoặc CNN trên tập dữ liệu MNIST).

3.1.2. Quy trình vận hành hệ thống

- Khởi tạo (Initialization): Quá trình bắt đầu từ Main Script gọi hàm `fedml.init()` để thiết lập môi trường phân tán.
- Khởi tạo máy chủ (Server Setup): `FedMLServerManager` được tạo ra tại Node Server (Rank 0), thực hiện khởi tạo mô hình toàn cục (Global model) và mở cổng giao tiếp gRPC.
- Khởi tạo máy trạm (Client Setup): Các `FedMLClientManager` tại các Node Client (Rank 1, 2...) kết nối đến máy chủ gRPC để nhận mô hình ban đầu.
- Vòng lặp huấn luyện:
 - Server gửi Global model tới các Client.
 - Các Client thực hiện huấn luyện cục bộ (Local training) trên dữ liệu riêng tư.
 - Các Client gửi tham số đã cập nhật (Local model) về Server thông qua giao thức gRPC.
 - Server tổng hợp các bản cập nhật bằng thuật toán FedAvg để tạo mô hình toàn cục mới và lặp lại quy trình.



Hình 3. Sơ đồ trình tự khởi tạo hệ thống FedML



Hình 4. Sơ đồ luồng giao tiếp và huấn luyện vòng lặp

3.2. Cài đặt

- Hạ tầng Microsoft Azure: Mỗi node trong hệ thống (Server và các Client) được triển khai trên một máy ảo (Virtual Machine) độc lập chạy hệ điều hành Ubuntu trên Azure. Việc sử dụng máy ảo độc lập giúp đảm bảo tính cô lập của dữ liệu, đúng với nguyên tắc cốt lõi của Federated Learning.
- Yêu cầu phần cứng: Để đảm bảo tiến trình huấn luyện không bị hệ điều hành tự động dừng (killed), mỗi node cần được cấu hình từ 8GB đến 16GB RAM.
- Cài đặt phần mềm:
 - Hệ thống yêu cầu Python phiên bản 3.7 trở lên.
 - Cài đặt thư viện FedML thông qua lệnh: `pip install fedml`.
- Công cụ giám sát: Hệ thống tích hợp Wandb (Weights & Biases) để theo dõi các chỉ số quan trọng như độ chính xác (Test/Acc) và độ lỗi (Test/Loss) theo thời gian thực.

3.3. Cấu hình và triển khai

Việc triển khai kịch bản huấn luyện được điều khiển thông qua các tệp cấu hình để đảm bảo tính nhất quán giữa các Node.

Cấu hình tham số huấn luyện (`fedml_config.yaml`):

- `raining_type`: Được đặt là `cross_silo` để huấn luyện giữa các Node độc lập.
- `scenario`: `horizontal` (Federated Learning ngang), trong đó các client có cùng không gian đặc trưng nhưng khác nhau về mẫu dữ liệu.
- `optimizer`: Sử dụng thuật toán FedAvg.
- Tham số khác: Định nghĩa số vòng liên lạc (`comm_round`), số lượng epoch cục bộ (`epochs`), kích thước lô (`batch_size`) và tốc độ học (`learning_rate`).

```
common_args:
  training_type: "cross_silo"
  scenario: "horizontal"
  using_mlops: false
  random_seed: 0

environment_args:
```

```
bootstrap: config/bootstrap.sh

data_args:
  dataset: "mnist"
  data_cache_dir: "../../data/mnist"
  partition_method: "hetero"
  partition_alpha: 0.5

model_args:
  model: "lr"
  model_file_cache_folder: "./model_file_cache"
  global_model_file_path: "./model_file_cache/global_model.pt"

train_args:
  federated_optimizer: "FedAvg"
  client_id_list:
  client_num_in_total: 1000
  client_num_per_round: 2
  comm_round: 50
  epochs: 1
  batch_size: 10
  client_optimizer: sgd
  learning_rate: 0.03
  weight_decay: 0.001

validation_args:
  frequency_of_the_test: 5

device_args:
  worker_num: 2
```

```
using_gpu: false
gpu_mapping_file: config/gpu_mapping.yaml
gpu_mapping_key: mapping_default

comm_args:
  backend: "GRPC"
  grpc_ipconfig_path: config/grpc_ipconfig.csv
```

- Cấu hình mạng gRPC (grpc_ipconfig.csv): Tập này định nghĩa danh sách địa chỉ IP của tất cả các node tham gia. Định dạng bắt buộc là receiver_id,ip, trong đó receiver_id = 0 luôn dành cho Server, các ID từ 1 trở đi dành cho các Client tương ứng.

```
receiver_id, ip,
0, 127.0.0.1
1, 127.0.0.1
2, 127.0.0.1
```

- Thực thi triển khai:

Người dùng khởi chạy Server trước bằng lệnh `bash run_server.sh`, sau đó kích hoạt các máy trạm bằng lệnh `bash run_client.sh [rank_id]`. Hệ thống sẽ tự động thiết lập kết nối và bắt đầu quy trình huấn luyện liên kết như đã thiết kế.

3.4. Triển khai các kịch bản thử nghiệm

Việc thực nghiệm được tiến hành trên tập dữ liệu MNIST với hai mô hình có độ phức tạp khác nhau để đánh giá khả năng vận hành của hệ thống.

– Cấu hình chung (fedml_config.yaml):

- Loại huấn luyện: cross_silo.
- Kịch bản: horizontal (dữ liệu phân tán ngang, các client có cùng không gian đặc trưng nhưng khác nhau về mẫu dữ liệu).
- Tập dữ liệu: MNIST.
- Thuật toán tổng hợp: FedAvg.

Kịch bản 1: Logistic Regression (1 Server - 2 Clients)

- Sử dụng mô hình Logistic Regression đơn giản để kiểm tra tính ổn định của luồng dữ liệu.
- Cấu hình thử nghiệm bao gồm các tham số biến thiên qua 5 lần chạy (Run 1-5) như: `learning_rate` (0.03 - 0.05) và `partition_alpha` (0.1 - 0.5) để quan sát sự hội tụ.
- Cách thực thi: Chạy script `bash run_server.sh` trên node server trước, sau đó lần lượt chạy `bash run_client.sh 1` và `bash run_client.sh 2` trên các máy trạm tương ứng.

Kịch bản 2: CNN (1 Server - 4 Clients)


- Sử dụng mô hình mạng thần kinh tích chập (CNN) để đánh giá hệ thống trong điều kiện khối lượng tính toán lớn hơn và số lượng client tăng lên.
- Kịch bản này thiết lập 50 vòng liên lạc (`comm_round`) để đảm bảo các tham số của mạng CNN được tối ưu hóa đầy đủ trên hạ tầng phân tán.

CHƯƠNG 4. KẾT QUẢ CÁC KỊCH BẢN THỬ NGHIỆM

4.1. Kết quả mô hình Logistic Regression (LR) trên MNIST (1 server – 2 clients):

- Dựa trên kết quả từ 5 lần chạy (run 1 - run 5), độ chính xác (Test Accuracy) đạt mức ổn định trong khoảng 0.7953 đến 0.8173.
- Phân tích cụ thể: Run 3 với tham số $\text{partition_alpha}=0.3$, $\text{learning_rate}=0.04$ đạt độ chính xác cao nhất (0.8173) trong thời gian rất ngắn (17.36s).
- Nhận xét biểu đồ: Đường Test/Loss có xu hướng giảm mạnh và đường Test/Acc tăng dần qua các bước (Step), minh chứng cho việc mô hình hội tụ tốt.

Run	epochs	batch_size	learning_rate	partition_alpha	Test/Acc	Test/Loss	TotalTime
run1	5	32	0.03	0.5	0.8098	0.8098	24.2
run2	20	64	0.05	0.1	0.7992	0.7992	17.32
run3	10	48	0.04	0.3	0.8173	1.812	17.36
run4	15	32	0.035	0.4	0.7953	1.804	20.07
run5	12	48	0.033	0.3	0.8173	1.8124	23.35



Hình 5. Đồ thị biểu diễn chỉ số Test/Loss và Test/Acc của kịch bản 1

4.2. Kết quả mô hình CNN trên MNIST (1 server- 4 clients):

- Mô hình CNN cho thấy độ chính xác dao động từ 0.6748 đến 0.7182 sau 50 vòng liên lạc (Comm Rounds).
- Đánh giá hiệu năng: Kịch bản cnn1 đạt kết quả tốt nhất (Acc: 0.7182) nhưng thời gian huấn luyện (197.11s) lâu hơn nhiều so với mô hình LR do độ phức tạp của mạng CNN và số lượng Client tăng lên.

Run	epochs	batch_size	learning_rate	partition_alpha	Test/Acc	Test/Loss	TotalTime
cnn1	12	48	0.036	0.3	0.7182	1.1733	197.11
cnn2	20	68	0.02	0.7	0.6748	1.3811	265.38
cnn3	15	64	0.035	0.5	0.7078	1.825	210.12



Hình 6. Đồ thị biểu diễn chỉ số Test/Loss và Test/Acc của kịch bản 2

CHƯƠNG 5. KẾT LUẬN

5.1. Kết quả đạt được:

- Xây dựng thành công hệ thống Federated Learning thực tế trên Azure bằng framework FedML.
- Đảm bảo được tính riêng tư của dữ liệu vì dữ liệu gốc luôn nằm tại Client và chỉ có tham số mô hình được trao đổi.
- Hệ thống có khả năng mở rộng tốt nhờ vào hạ tầng đám mây của Azure.

5.2. Hạn chế và khó khăn:

- Ngân sách dành cho nền tảng MLOps còn hạn chế.
- FedML vẫn là một framework mới, tài liệu hỗ trợ chưa thực sự phong phú.
- Gặp lỗi xác thực AWS Access Key khi cố gắng truy cập vào hệ thống lưu trữ S3 trong quá trình triển khai.

5.3. Hướng phát triển:

- Nghiên cứu áp dụng các thuật toán tổng hợp khác ngoài FedAvg (như FedOpt, FedNova) có sẵn trong FedML.
- Thử nghiệm trên các tập dữ liệu thực tế và phức tạp hơn để đánh giá khả năng chịu lỗi và hiệu suất truyền thông của hệ thống.

TÀI LIỆU THAM KHẢO

- [1] FedML Team. FedML – A Research Library and Platform for Federated Learning. Available at: <https://fedml.ai>, truy cập ngày 10/12/2025.
- [2] FedML Team. FedML: A Research Library for Federated Learning. GitHub repository. Available at: <https://github.com/FedML-AI/FedML>, truy cập ngày 10/12/2025.
- [3] Weights & Biases. Weights & Biases Documentation. Available at: <https://docs.wandb.ai>, truy cập ngày 10/12/2025.

HẾT