

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG**



**NGUYỄN LÊ HẠ MY – 23520964
BÙI NGUYỄN TƯỜNG VÂN – 23521768
TRẦN NGỌC THÚY VY – 23521837**

ĐỒ ÁN MÔN HỌC

**ỨNG DỤNG HỌC MÁY TĂNG CƯỜNG TRONG RA QUYẾT ĐỊNH ĐIỀU
KHIỂN VÀ GIẢM THIỂU TẦN CÔNG MẠNG CHO MẠNG SDN**

NT549.Q21 - HỌC MÁY TĂNG CƯỜNG CHO CÁC HỆ THỐNG MẠNG

**GIẢNG VIÊN HƯỚNG DẪN
TS. Huỳnh Văn Đăng**

TP. HỒ CHÍ MINH, 2026

TÓM TẮT

Đề tài tập trung giải quyết thách thức về an ninh trong kiến trúc mạng khả lập trình Software-Defined Networking (SDN). Trong bối cảnh các phương pháp bảo mật truyền thống dần bộc lộ hạn chế trước các cuộc tấn công, nghiên cứu này đề xuất một hệ thống phòng thủ tự động dựa trên Học máy tăng cường - Reinforcement Learning (RL) có khả năng thích nghi theo thời gian thực.

Hệ thống được thiết kế theo mô hình vòng lặp tương tác khép kín (Closed-Loop Interaction), tích hợp trực tiếp với bộ điều khiển ONOS. Tác tử AI (Agent) thực hiện quan sát trạng thái mạng thông qua vector 9 chiều và đưa ra các hành động phòng thủ linh hoạt như: chặn luồng (Block), giới hạn băng thông (Rate Limiting), chuyển hướng lưu lượng (Redirect) hoặc cô lập thiết bị (Isolate). Quá trình ra quyết định được tối ưu hóa bởi hàm phần thưởng (Reward Function) đa mục tiêu, giúp cân bằng giữa hiệu quả bảo mật và duy trì chất lượng dịch vụ (QoS).

Kết quả thực nghiệm trên môi trường mô phỏng Mininet cho thấy thuật toán Proximal Policy Optimization (PPO) đạt hiệu năng vượt trội và độ ổn định cao hơn so với Deep Q-Network (DQN). Cụ thể, PPO đạt được sự hội tụ chính xác về chính sách tối ưu trên nhiều giá trị khởi tạo huấn luyện khác nhau ($p\text{-value} < 0.001$), đồng thời duy trì tỷ lệ nhảy luật (Switching Rate) xấp xỉ bằng 0, giúp giảm thiểu rủi ro vận hành mạng. Đề tài không chỉ chứng minh tiềm năng của RL trong việc tự động hóa bảo mật SDN mà còn đặt nền móng cho việc tích hợp các công nghệ tiên tiến như bản sao kỹ thuật số - Digital Twin (DT) và mô hình ngôn ngữ lớn - Large Language Model (LLM) vào quản trị mạng thông minh trong tương lai.

MỤC LỤC

Tóm tắt	i
Mục lục	ii
Danh mục các bảng	vii
Danh mục các hình vẽ và đồ thị	viii
Danh mục từ viết tắt	ix
Chương 1. Giới thiệu	1
1.1 Lý do chọn đề tài	1
1.2 Các nghiên cứu liên quan	2
1.3 Mục tiêu, đối tượng và phạm vi nghiên cứu	3
1.3.1 Mục tiêu nghiên cứu	3
1.3.2 Đối tượng nghiên cứu	4
1.3.3 Phạm vi nghiên cứu	4
Chương 2. Tổng quan lý thuyết	6
2.1 Học máy tăng cường - Reinforcement Learning	6
2.1.1 Tổng quan Reinforcement Learning	6
2.1.2 Mô hình Markov Decision Process (MDP)	7
2.1.3 Deep Reinforcement Learning	7
2.1.4 Thuật toán Deep Q-Network (DQN)	8
2.2 Multi-Seed Training	8
2.2.1 Thuật toán Proximal Policy Optimization (PPO)	9
2.2.2 Ứng dụng RL trong điều khiển mạng	10
2.3 Mạng khả lập trình - Software Defined Networking	10
2.3.1 Kiến trúc Software Defined Networking	11
2.3.2 SDN Controller và cơ chế điều khiển	12
2.3.3 Các loại tấn công trong SDN	13
2.3.3.1 Tấn công Từ chối dịch vụ phân tán (DDoS)	13

2.3.3.2	Tấn công cạn kiệt tài nguyên Controller (Packet-In Flood)	14
2.3.3.3	Tấn công tràn bảng luồng (Flow Table Overflow)	14
2.3.3.4	Tấn công giả mạo luồng dữ liệu (Traffic & IP Spoofing)	15
2.3.3.5	Tấn công dò quét và rò rỉ thông tin (Information Disclosure & Scanning)	15
2.3.4	Các phương pháp phòng vệ truyền thống	16
2.3.4.1	Phòng chống tấn công DDoS	16
2.3.4.2	Phòng chống giả mạo luồng (Spoofing Attack)	16
2.3.4.3	Phòng chống rò rỉ thông tin (Information Disclosure)	17
2.3.4.4	Bảo mật SDN Controller	17
2.3.4.5	Tổng kết giải pháp phòng vệ	18
2.3.5	Các chỉ số đánh giá hệ thống mạng	18
2.4	Các nghiên cứu liên quan	19
2.4.1	Ứng dụng RL trong SDN	20
2.4.2	RL trong phát hiện và giảm thiểu tấn công mạng	20
2.4.2.1	Phương pháp ML/DL truyền thống	21
2.4.2.2	Reinforcement Learning trong mitigation	21
2.4.3	So sánh với các phương pháp truyền thống	22
2.4.3.1	Rule-based	22
2.4.3.2	Machine Learning / Deep Learning	22
2.4.3.3	Reinforcement Learning	22
2.4.4	Nhận xét và khoảng trống trong nghiên cứu	23
2.4.4.1	Ưu điểm chung	23
2.4.4.2	Hạn chế	23
2.4.4.3	Khoảng trống nghiên cứu	23
2.4.4.4	Định hướng của đề tài	24
Chương 3.	Mô hình bài toán	25
3.1	Không gian trạng thái (State Space)	25

3.1.1	Packet Rate	26
3.1.2	Byte Rate	26
3.1.3	Flow Count	27
3.1.4	Source IP Entropy	27
3.1.5	Latency	27
3.1.6	Packet Loss	28
3.1.7	Queue Length	28
3.1.8	Controller CPU	28
3.1.9	Previous Action	29
3.2	Thu thập dữ liệu và xây dựng môi trường mạng	29
3.3	Không gian hành động - Action Space	31
3.3.1	No Action	31
3.3.2	Block Suspicious Flow	31
3.3.3	Limit Bandwidth	31
3.3.4	Redirect Traffic	32
3.3.5	Isolate Device	32
3.4	Hàm thưởng - Reward Function	32
3.4.1	QoS Penalty	32
3.4.2	Security Reward	33
3.4.3	Stability Penalty	33
Chương 4.	Phương pháp đề xuất	34
4.1	Kiến trúc hệ thống	34
4.2	Multi-Seed Training	36
4.3	Offline - Online Validation	36
4.3.1	Offline Validation	36
4.3.1.1	Chuẩn bị và tiền xử lý dữ liệu kiểm thử	37
4.3.1.2	Môi trường đánh giá Offline	37
4.3.1.3	Không gian trạng thái và hành động	37
4.3.1.4	Hàm phần thưởng đánh giá	38
4.3.1.5	Các chỉ số đo lường hiệu năng	39

4.3.2	Online Validation	39
4.3.2.1	Môi trường đánh giá Online	39
4.3.2.2	Không gian trạng thái và hành động	39
4.3.2.3	Cơ chế phản hồi và cập nhật trạng thái	41
4.3.2.4	Các chỉ số đo lường hiệu năng	41
Chương 5.	Cài đặt và thực nghiệm	42
5.1	Môi trường thực nghiệm và Triển khai	42
5.2	Cấu hình huấn luyện	42
5.2.1	Thiết lập không gian Trạng thái và Hành động	42
5.2.2	Hàm phần thưởng (Reward Function)	43
5.3	Thuật toán và tham số huấn luyện	43
5.3.1	Thuật toán Deep Q-Network (DQN)	43
5.3.2	Thuật toán Proximal Policy Optimization (PPO)	44
5.4	Phương pháp đánh giá và Kịch bản thử nghiệm	45
5.4.1	Chỉ số đánh giá	45
5.4.2	Kịch bản thử nghiệm	46
Chương 6.	Kết quả và phân tích	47
6.1	So sánh tổng thể hiệu năng	47
6.2	Độ ổn định và khả năng hội tụ với huấn luyện Multi-seed	48
6.2.1	Phân tích đường cong huấn luyện (Learning Curve)	48
6.2.2	Độ ổn định thống kê (Stability)	49
6.3	Phân tích tỷ lệ nhảy luật (Switching Rate)	50
6.4	Phân tích hiệu năng theo kịch bản	51
6.5	Nhận xét chung	53
Chương 7.	Kết luận và hướng phát triển	54
7.1	Kết luận	54
7.2	Hạn chế	54
7.3	Hướng phát triển	55
7.3.1	Tích hợp công nghệ Digital Twin	55

MỤC LỤC

7.3.2 Tích hợp LLM hỗ trợ quản trị	55
Tài liệu tham khảo	58

DANH MỤC CÁC BẢNG

2.1	Bảng so sánh tổng hợp các phương pháp bảo mật SDN.	23
5.1	Siêu tham số cấu hình cho tác tử DQN	44
5.2	Siêu tham số cấu hình cho tác tử PPO	45

DANH MỤC CÁC HÌNH VẼ VÀ ĐỒ THỊ

2.1	Hoạt động của thuật toán DQN.	8
2.2	Hoạt động của thuật toán PPO.	9
3.1	Topology mạng SDN được sử dụng trong hệ thống đề xuất.	29
4.1	Kiến trúc hệ thống đề xuất.	36
6.1	Biểu đồ phân phối phần thưởng của các phương pháp.	47
6.2	Phân tích hiệu năng huấn luyện của thuật toán DQN và PPO qua đa giá trị khởi tạo.	49
6.3	Biểu đồ thể hiện tỷ lệ nhảy luật của thuật toán.	51
6.4	So sánh phần thưởng trung bình giữa các phương pháp theo từng kịch bản.	52
6.5	Ma trận nhiệt thể hiện phân phối phần thưởng theo kịch bản và mô hình.	52

DANH MỤC TỪ VIẾT TẮT

AI	Artificial Intelligence
API	Application Programming Interface
DDoS	Distributed Denial of Service
DDQN	Double Deep Q-Network
DL	Deep Learning
DNN	Deep Neural Networks
DQN	Deep Q-Network
DRL	Deep Reinforcement Learning
DT	Digital Twin
IAD	IP Address Database
IoT	Internet of Things
IoT	Internet of Things
IoT	Internet of Things
LLM	Large Language Model
MDP	Markov Decision Process
PPO	Proximal Policy Optimization
QoS	Quality of Service
RL	Reinforcement Learning
SDN	Software-Defined Networking

Chương 1. GIỚI THIỆU

1.1 Lý do chọn đề tài

Trong những năm gần đây, sự phát triển mạnh mẽ của các công nghệ như Internet of Things (IoT), điện toán đám mây và mạng 5G đã làm gia tăng đáng kể quy mô và độ phức tạp của hệ thống mạng. Điều này kéo theo sự xuất hiện ngày càng nhiều của các cuộc tấn công mạng, đặc biệt là các cuộc tấn công từ chối dịch vụ phân tán - Distributed Denial of Service (DDoS), quét cổng, xâm nhập trái phép và các hình thức tấn công thông minh khác. Các phương pháp bảo mật truyền thống chủ yếu dựa trên luật cố định hoặc cấu hình thủ công đang dần bộc lộ nhiều hạn chế như phản ứng chậm, khó thích nghi với môi trường mạng thay đổi liên tục và khó xử lý các cuộc tấn công mới chưa từng xuất hiện trước đó.

Mạng khả lập trình - SDN được xem là một giải pháp tiềm năng nhằm nâng cao khả năng quản lý và điều khiển mạng nhờ kiến trúc điều khiển tập trung. Tuy nhiên, chính đặc tính tập trung này cũng khiến SDN trở thành mục tiêu hấp dẫn của các cuộc tấn công mạng, đặc biệt là các cuộc tấn công nhắm vào bộ điều khiển trung tâm.

Trước thực tế đó, nhiều nghiên cứu gần đây đã tập trung ứng dụng Trí tuệ nhân tạo - Artificial Intelligence (AI), Học sâu - Deep Learning (DL) và đặc biệt là Học tăng cường vào các hệ thống bảo mật SDN nhằm xây dựng các cơ chế phòng thủ tự động, có khả năng tự học và thích nghi với môi trường mạng theo thời gian thực. Các nghiên cứu như QoSentry [1], DAMS [2] hay DeepIDPS [3] cho thấy các mô hình RL và Deep Reinforcement Learning (DRL) có khả năng đưa ra quyết định phòng thủ linh hoạt, tối ưu hóa hiệu suất mạng đồng thời giảm thiểu tác động của các cuộc tấn công mạng.

Xuất phát từ những vấn đề trên, nhóm lựa chọn đề tài **“Ứng dụng học máy tăng cường trong ra quyết định điều khiển và giảm thiểu tấn công cho mạng khả lập trình”** nhằm nghiên cứu và xây dựng một mô hình bảo mật tự động cho môi trường SDN dựa trên học máy tăng cường, góp phần nâng cao khả năng phát hiện, phản ứng và giảm thiểu các cuộc tấn công mạng trong hệ thống mạng hiện đại.

1.2 Các nghiên cứu liên quan

Hiện nay đã có nhiều nghiên cứu ứng dụng trí tuệ nhân tạo và học tăng cường vào lĩnh vực bảo mật mạng SDN. Các nghiên cứu này chủ yếu tập trung vào việc phát hiện xâm nhập, giảm thiểu tấn công DDoS và tối ưu hóa hiệu suất mạng trong môi trường động.

Nghiên cứu QoSentry [1] đề xuất một framework sử dụng Double Deep Q-Network (DDQN) để giảm thiểu tấn công DDoS trong SDN đồng thời đảm bảo chất lượng dịch vụ cho người dùng hợp pháp. Hệ thống có khả năng tự động điều chỉnh băng thông và định tuyến lưu lượng theo trạng thái mạng thời gian thực.

Nghiên cứu DAMS [2] cũng áp dụng mô hình DDQN nhằm tự động lựa chọn và triển khai các biện pháp giảm thiểu tấn công trong môi trường SDN. Kết quả cho thấy hệ thống giúp giảm đáng kể độ trễ mạng và tăng tỷ lệ truyền thành công của lưu lượng hợp pháp trong điều kiện bị tấn công.

Trong khi đó, DeepIDPS [3] sử dụng kiến trúc CNN-LSTM kết hợp cơ chế Attention để xây dựng hệ thống phát hiện và ngăn chặn xâm nhập thích nghi cho SDN. Hệ thống đạt độ chính xác cao trong việc phát hiện nhiều loại tấn công khác nhau như DDoS, quét cổng và zero-day attacks.

Các nghiên cứu về ứng dụng học máy tăng cường trong mạng khả lập trình đã chứng minh khả năng vượt trội trong việc cải thiện giám sát lưu lượng và tối ưu hóa hiệu năng hệ thống [4]. Bên cạnh đó, các cơ chế học thích nghi gần đây cũng cho thấy hiệu quả trong tối ưu hóa định tuyến và đảm bảo chất lượng dịch vụ - Quality of Service (QoS) [5]. Tuy nhiên, thực tế cho thấy nếu thiếu các cơ chế phản ứng thông minh, các cuộc tấn công mạng có thể gây suy giảm nghiêm trọng đến hiệu năng và QoS của toàn hệ thống.

Bên cạnh các hướng tiếp cận học tăng cường, nhiều nghiên cứu khác cũng đã đạt được kết quả khả quan trong việc sử dụng Học máy (ML) và Học sâu (DL) thuần túy để nhận diện lưu lượng bất thường. Cụ thể, nghiên cứu trong [6] tập trung vào việc phát hiện tấn công DDoS trên kiến trúc SDN bằng các thuật toán phân loại dựa trên AI. Tương tự, nghiên cứu trong [7] đề xuất các giải pháp ML và DL để phân loại các loại hình tấn công khác nhau trên hạ tầng mạng khả lập trình.

1.3. MỤC TIÊU, ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

Tuy nhiên, các phương pháp này chủ yếu giới hạn ở việc thực hiện phân loại nhị phân (Binary Classification) hoặc phân loại đa lớp (Multi-class Classification) để xác định sự hiện diện của tấn công. Mặc dù đạt độ chính xác cao trong việc nhận diện, các mô hình này vẫn mang tính chất "tĩnh", tức là chỉ dừng lại ở bước đưa ra cảnh báo mà chưa có cơ chế tác động trực tiếp hoặc phản ứng linh hoạt để ngăn chặn và giảm thiểu tấn công ngay tại thời điểm xảy ra (real-time mitigation). Đây chính là khoảng trống mà RL có thể lấp bằng khả năng tương tác và ra quyết định điều khiển dựa trên sự thay đổi liên tục của trạng thái mạng.

Mặc dù đạt được nhiều kết quả khả quan, các hướng tiếp cận RL hiện nay trong SDN vẫn tồn tại một số hạn chế nhất định:

- **Phạm vi đánh giá:** Phần lớn nghiên cứu chỉ tập trung vào tối ưu hóa hiệu suất hoặc giảm thiểu tấn công dựa trên các tiêu chí phần thưởng (reward) nội bộ của mô hình, mà chưa đánh giá toàn diện tác động của chính sách điều khiển đến QoS ở đa cấp độ như: packet-level, queue-level và policy-level.
- **Tính thực tiễn:** Chi phí huấn luyện mô hình còn cao và thách thức trong việc triển khai trên các môi trường mạng thực tế quy mô lớn vẫn là rào cản đáng kể.
- **Tính minh bạch và tích hợp:** Khả năng giải thích (explainability) các quyết định của mô hình còn hạn chế, đồng thời việc kết hợp đồng bộ nhiều công nghệ mới trong cùng một hệ thống chưa được khai thác triệt để.

Xuất phát từ những khoảng trống nghiên cứu trên, đề tài này tập trung vào việc nghiên cứu và phát triển giải pháp nhằm khắc phục các hạn chế hiện có, hướng tới một hệ thống quản trị mạng thông minh và bền vững hơn.

1.3 Mục tiêu, đối tượng và phạm vi nghiên cứu

1.3.1 Mục tiêu nghiên cứu

Đề tài hướng đến việc nghiên cứu và xây dựng một hệ thống bảo mật mạng SDN ứng dụng Học máy tăng cường nhằm hỗ trợ phát hiện, ra quyết định điều khiển và giảm thiểu các cuộc tấn công mạng một cách tự động. Các mục tiêu cụ thể bao gồm:

- **Nghiên cứu kiến trúc SDN:** Tìm hiểu kiến trúc và cơ chế hoạt động của mạng SDN.
- **Khảo sát thuật toán Học tăng cường:** Nghiên cứu các thuật toán Học tăng cường và khả năng ứng dụng vào lĩnh vực bảo mật mạng.
- **Xây dựng môi trường mô phỏng:** Thiết lập môi trường SDN phục vụ quá trình huấn luyện và đánh giá mô hình.
- **Thiết kế mô hình RL phòng thủ:** Xây dựng mô hình RL có khả năng giám sát trạng thái mạng và đưa ra các hành động phòng thủ phù hợp.
- **Đánh giá hiệu năng hệ thống:** Đánh giá hiệu quả của mô hình thông qua các chỉ số như độ trễ, thông lượng, tỷ lệ phát hiện và khả năng giảm thiểu tấn công.

1.3.2 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm:

- Mạng khả lập trình SDN và kiến trúc điều khiển tập trung.
- Các cuộc tấn công mạng phổ biến trong môi trường SDN như DDoS, TCP SYN Flood, UDP Flood và các hành vi bất thường khác.
- Các thuật toán Học tăng cường và Học tăng cường sâu tiêu biểu như Deep Q-Network (DQN) và Proximal Policy Optimization (PPO).
- Các cơ chế giám sát, điều khiển và giảm thiểu tấn công trong hệ thống mạng.
- Các nền tảng đóng gói ứng dụng (Containerization), quản lý thực nghiệm học máy (MLFlow) và giám sát hệ thống phân tán (Prometheus, Grafana).

1.3.3 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu và triển khai mô hình trong môi trường mô phỏng SDN sử dụng các nền tảng như Mininet và OpenFlow Controller. Phạm vi nghiên cứu cụ thể của đề tài bao gồm:

1.3. MỤC TIÊU, ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

- **Xây dựng môi trường SDN mô phỏng:** Thiết lập môi trường mạng SDN ở quy mô nhỏ và trung bình phục vụ quá trình thực nghiệm.
- **Mô phỏng các kịch bản tấn công mạng:** Thực hiện mô phỏng đa dạng các hình thức tấn công khai thác đặc thù của kiến trúc SDN bao gồm: tấn công từ chối dịch vụ phân tán (*DDoS Flood*), tấn công cạn kiệt tài nguyên bộ điều khiển (*Packet-In Flood*), tấn công tràn bảng luồng (*Flow Table Overflow*), giả mạo địa chỉ (*IP Spoofing*) và dò quét dịch vụ (*Port Scanning*) nhằm đánh giá toàn diện khả năng phòng thủ và ra quyết định của hệ thống.
- **Ứng dụng thuật toán Học tăng cường:** Triển khai các thuật toán Reinforcement Learning như DQN và PPO trong việc ra quyết định điều khiển và giảm thiểu tấn công dựa trên trạng thái mạng.
- **Triển khai hệ thống bằng Containerization:** Thiết kế và vận hành toàn bộ hệ thống, bao gồm Controller, agent AI và các công cụ thu thập lưu lượng, dưới dạng container Docker nhằm đảm bảo tính linh hoạt và cô lập khi triển khai.
- **Tích hợp công cụ huấn luyện và hệ thống giám sát:** Kết hợp các nền tảng như MLflow, Prometheus và Grafana để theo dõi trực quan, lưu trữ thông số thực nghiệm và hỗ trợ đánh giá mô hình.
- **Đánh giá hiệu quả mô hình:** Phân tích hiệu năng hệ thống dựa trên các chỉ số mạng, giá trị phần thưởng (reward) cũng như khả năng hội tụ và thích nghi của agent AI.

Đề tài hiện tại tập trung trong giới hạn mô phỏng, chưa mở rộng triển khai trên hạ tầng mạng thực tế quy mô lớn, đồng thời chưa đi sâu vào nghiên cứu các cơ chế bảo mật vật lý hoặc bảo mật phần cứng chuyên dụng.

Chương 2. TỔNG QUAN LÝ THUYẾT

Chương này trình bày các nền tảng lý thuyết làm cơ sở cho việc xây dựng mô hình trong đề án. Trước hết, chương giới thiệu tổng quan về Học máy tăng cường, bao gồm các khái niệm cơ bản, mô hình Markov Decision Process (MDP) và các thuật toán tiêu biểu như DQN và PPO, nhằm làm rõ cơ chế học và ra quyết định của agent.

Tiếp theo, chương trình bày về kiến trúc mạng khả lập trình, các thành phần chính, cơ chế điều khiển, cùng với các dạng tấn công phổ biến và phương pháp phòng chống trong môi trường SDN.

Cuối cùng, chương tổng hợp các nghiên cứu liên quan, so sánh các phương pháp tiếp cận truyền thống và hiện đại, từ đó rút ra nhận xét và xác định khoảng trống nghiên cứu, làm cơ sở định hướng cho mô hình đề xuất ở các chương tiếp theo.

2.1 Học máy tăng cường - Reinforcement Learning

2.1.1 Tổng quan Reinforcement Learning

Học máy tăng cường RL là một nhánh của học máy, tập trung vào việc huấn luyện các tác nhân (agent) học cách đưa ra quyết định tối ưu thông qua quá trình tương tác thử và sai với môi trường (environment). Thay vì học từ dữ liệu có nhãn như trong học có giám sát, RL cho phép tác nhân tự khám phá và cải thiện chiến lược dựa trên phản hồi nhận được từ môi trường.

- **Cơ chế hoạt động:** Tại mỗi bước thời gian, tác nhân quan sát trạng thái s của môi trường, thực hiện một hành động a , và nhận được phần thưởng r cùng với trạng thái tiếp theo s' . Quá trình này lặp lại liên tục, giúp tác nhân học được cách tối ưu hành vi.
- **Mục tiêu:** Tác nhân hướng đến việc học một chính sách (policy) π nhằm tối đa hóa tổng phần thưởng tích lũy có chiết khấu theo thời gian.
- **Đặc điểm:** Khác với học có giám sát, RL không phụ thuộc vào tập dữ liệu được gán nhãn sẵn mà học trực tiếp từ kinh nghiệm tương tác và phản hồi từ môi trường.

2.1. HỌC MÁY TĂNG CƯỜNG - REINFORCEMENT LEARNING

2.1.2 Mô hình Markov Decision Process (MDP)

Trong học máy tăng cường, môi trường tương tác thường được mô hình hóa dưới dạng Quy trình quyết định - MDP. Một mô hình MDP tiêu chuẩn được biểu diễn bởi bộ 5 thành phần (S, A, P, R, γ) .

- **S (State space):** Tập hợp tất cả các trạng thái có thể có của môi trường.
- **A (Action space):** Tập hợp các hành động mà tác nhân có thể thực hiện.
- **P (Transition probability):** Xác suất chuyển từ trạng thái s sang trạng thái s' khi thực hiện hành động a , được biểu diễn dưới dạng $P(s'|s, a)$.
- **R (Reward function):** Hàm phần thưởng xác định giá trị phản hồi mà tác nhân nhận được sau mỗi cặp trạng thái – hành động.
- **γ (Discount factor):** Hệ số chiết khấu ($0 \leq \gamma \leq 1$), dùng để cân bằng giữa phần thưởng tức thời và phần thưởng trong tương lai.

Một đặc tính quan trọng của MDP là *tính chất Markov*, trong đó trạng thái hiện tại chứa đầy đủ thông tin cần thiết để đưa ra quyết định cho tương lai mà không cần phụ thuộc vào các trạng thái trước đó.

2.1.3 Deep Reinforcement Learning


Học máy tăng cường sâu - DRL là sự kết hợp giữa khả năng biểu diễn và trích xuất đặc trưng của học sâu với khả năng ra quyết định của RL. DRL cho phép giải quyết các bài toán có không gian trạng thái và hành động lớn hoặc liên tục mà các phương pháp RL truyền thống khó xử lý hiệu quả.

- **Vai trò:** DRL sử dụng các mạng nơ-ron sâu - Deep Neural Networks (DNN) để xấp xỉ các hàm giá trị (value function) hoặc chính sách (policy). Điều này giúp tác nhân có thể học và ra quyết định trong các môi trường phức tạp, nơi mà các phương pháp như bảng Q (Q-table) không còn khả thi do giới hạn về kích thước.

- **Ưu điểm:** DRL có khả năng tự động trích xuất các đặc trưng quan trọng từ dữ liệu đầu vào thô (ví dụ như dữ liệu lưu lượng mạng), từ đó hỗ trợ việc ra quyết định chính xác và hiệu quả trong các môi trường động và không chắc chắn.

2.1.4 Thuật toán Deep Q-Network (DQN)

DQN là một thuật toán học máy tăng cường sâu kết hợp giữa Q-learning và mạng nơ-ron để xấp xỉ hàm giá trị hành động $Q(s, a)$. Phương pháp này cho phép giải quyết các bài toán có không gian trạng thái lớn mà bảng Q truyền thống không thể xử lý hiệu quả.



Hình 2.1. Hoạt động của thuật toán DQN.

2.2 Multi-Seed Training

- **Quy tắc cập nhật:** DQN huấn luyện mạng nơ-ron bằng cách tối thiểu hóa sai số giữa giá trị Q dự đoán và giá trị mục tiêu (Temporal Difference error). Hàm mất mát được biểu diễn như sau:

$$L(\theta) = \mathbb{E} \left[\left(r_t + \gamma \max_{a'} Q(s_{t+1}, a'; \theta^-) - Q(s_t, a_t; \theta) \right)^2 \right]$$


- **Kỹ thuật then chốt:** DQN sử dụng bộ nhớ trải nghiệm (experience replay) để lưu trữ các mẫu (s, a, r, s') và huấn luyện lại một cách ngẫu nhiên nhằm giảm sự tương quan giữa các mẫu dữ liệu. Ngoài ra, mạng đích (target network) với tham số θ^- được cập nhật định kỳ giúp ổn định quá trình học.

2.2. MULTI-SEED TRAINING

- **Double Deep Q-Network (DDQN):** Đây là một biến thể cải tiến của DQN nhằm khắc phục hiện tượng ước tính quá cao (overestimation bias). DDQN tách biệt quá trình chọn hành động và đánh giá hành động bằng hai mạng nơ-ron khác nhau, từ đó cải thiện độ chính xác của giá trị Q.

2.2.1 Thuật toán Proximal Policy Optimization (PPO)

PPO là một thuật toán thuộc họ Chính sách Gradient (Policy Gradient), được xem là một trong những phương pháp học máy tăng cường sâu tiên tiến và ổn định nhất hiện nay. Khác với các phương pháp dựa trên hàm giá trị như DQN, PPO tối ưu hóa trực tiếp chính sách π để xác định xác suất thực hiện hành động tối ưu.



Hình 2.2. Hoạt động của thuật toán PPO.

- **Cơ chế:** PPO trực tiếp học chính sách $\pi(a|s)$ nhằm tối đa hóa phần thưởng kỳ vọng, thay vì ước lượng giá trị $Q(s, a)$. Điều này giúp mô hình phù hợp hơn với các bài toán có không gian hành động liên tục.
- **Hàm mục tiêu bị cắt (Clipped Objective):** Điểm nổi bật của PPO là sử dụng cơ chế cắt (clipping) để giới hạn mức thay đổi của chính sách trong mỗi lần cập nhật, từ đó đảm bảo sự ổn định trong quá trình huấn luyện. Hàm mục tiêu được biểu diễn như sau:

$$L_{CLIP}(\theta) = \mathbb{E}_t [\min (r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)]$$

CHƯƠNG 2. TỔNG QUAN LÝ THUYẾT

trong đó $r_t(\theta)$ là tỷ lệ xác suất giữa chính sách mới và chính sách cũ, $\hat{A}_t$ là ước lượng lợi thế (advantage), và ϵ là hệ số giới hạn mức thay đổi.

- **Hiệu quả:** PPO đạt hiệu năng cao trong các bài toán điều khiển liên tục và có sự cân bằng tốt giữa độ phức tạp tính toán và tốc độ hội tụ, do đó được sử dụng rộng rãi trong nhiều ứng dụng thực tế.

2.2.2 Ứng dụng RL trong điều khiển mạng

Nhờ tính linh hoạt và khả năng tự thích ứng, học máy tăng cường (RL/DRL) được ứng dụng rộng rãi trong kiến trúc mạng SDN và các hệ thống mạng thế hệ mới.

- **An ninh mạng:** RL cho phép tự động phát hiện và giảm thiểu các cuộc tấn công như DDoS thông qua việc điều chỉnh băng thông, thay đổi đường đi (rerouting) hoặc chặn địa chỉ IP. Ngoài ra, RL còn hỗ trợ phát hiện tấn công Man-in-the-Middle và phân loại mã độc trong mạng.
- **Tối ưu hóa quản lý mạng:** RL được sử dụng để thực hiện cân bằng tải (load balancing) động giữa các bộ điều khiển SDN, đồng thời tối ưu hóa định tuyến nhằm cải thiện thông lượng và giảm độ trễ trong hệ thống.
- **Quản lý tường lửa:** RL hỗ trợ tự động hóa việc xây dựng và tối ưu các quy tắc tường lửa thích nghi (Adaptive Firewall), giúp giảm thiểu sự phụ thuộc vào cấu hình thủ công và nâng cao hiệu quả bảo mật.
- **Phân bổ tài nguyên:** RL giúp điều phối tài nguyên một cách linh hoạt trong các môi trường mạng phức tạp như 5G/6G và Internet vạn vật Internet of Things (IoT), đồng thời tối ưu hóa mức tiêu thụ năng lượng.

2.3 Mạng khả lập trình - Software Defined Networking

SDN là một kiến trúc mạng hiện đại cho phép quản lý và điều khiển hệ thống mạng thông qua phần mềm. Điểm cốt lõi của SDN là tách biệt giữa mặt điều khiển (*Control Plane*) và mặt chuyển tiếp dữ liệu (*Data Plane*), giúp việc quản trị mạng trở nên linh hoạt, dễ lập trình và tự động hóa hơn so với mô hình mạng truyền thống.

2.3.1 Kiến trúc Software Defined Networking

a) Lớp ứng dụng (Application Layer)

Lớp ứng dụng chứa các ứng dụng và dịch vụ mạng như hệ thống phát hiện xâm nhập, cân bằng tải, tường lửa, ... Các ứng dụng này hoạt động trên nền phần mềm và giao tiếp với lớp điều khiển để yêu cầu xử lý và quản lý lưu lượng mạng. Việc sử dụng phần mềm giúp thay thế các thiết bị phần cứng truyền thống, từ đó tăng tính linh hoạt và khả năng mở rộng.

b) Lớp điều khiển (Control Layer)

Lớp điều khiển đóng vai trò là trung tâm xử lý của toàn bộ hệ thống SDN. Bộ điều khiển (SDN Controller) có nhiệm vụ quản lý, điều phối và đưa ra quyết định về định tuyến, điều khiển lưu lượng cũng như áp dụng các chính sách mạng. Lớp này cung cấp cái nhìn tổng thể về toàn bộ hệ thống, giúp quản trị viên dễ dàng cấu hình và giám sát mạng.

c) Lớp cơ sở hạ tầng (Infrastructure Layer / Data Plane)

Lớp cơ sở hạ tầng bao gồm các thiết bị mạng vật lý như switch, router, ... có nhiệm vụ chính là chuyển tiếp gói tin. Các thiết bị này không tự quyết định đường đi của dữ liệu mà hoạt động theo chỉ thị từ lớp điều khiển, giúp đơn giản hóa chức năng và tăng hiệu quả xử lý.

d) Giao tiếp giữa các lớp (APIs)

Các lớp trong kiến trúc SDN giao tiếp với nhau thông qua các giao diện lập trình ứng dụng Application Programming Interface (API), bao gồm:

- **Northbound API:** Cho phép lớp ứng dụng giao tiếp với lớp điều khiển để yêu cầu dịch vụ mạng và truy xuất thông tin.
- **Southbound API:** Cho phép lớp điều khiển giao tiếp với các thiết bị mạng trong lớp hạ tầng. Giao thức phổ biến nhất là OpenFlow.

e) Nguyên lý hoạt động

SDN hoạt động dựa trên nguyên lý tách biệt giữa mặt phẳng điều khiển (*Control Plane*) và mặt phẳng dữ liệu (*Data Plane*). Khi một gói tin đến thiết bị mạng, nếu chưa có quy tắc xử lý, thiết bị sẽ gửi yêu cầu đến bộ điều khiển. Bộ điều khiển sẽ phân tích và gửi lại quy tắc phù hợp, từ đó thiết bị thực hiện chuyển tiếp dữ liệu theo chỉ định.

2.3.2 SDN Controller và cơ chế điều khiển

Trong kiến trúc mạng SDN, Controller đóng vai trò là “bộ não” trung tâm, chịu trách nhiệm quản lý trạng thái toàn mạng và đưa ra các quyết định điều khiển đối với các thiết bị chuyển mạch ở lớp dữ liệu. Trong phạm vi đề án này, hệ điều hành mạng mã nguồn mở ONOS được lựa chọn làm Controller cốt lõi nhờ sở hữu hiệu năng xử lý cao, khả năng mở rộng tốt cùng hệ thống API phong phú, phù hợp cho việc xây dựng các cơ chế giám sát và bảo mật thông minh trong môi trường SDN.

Về cơ chế hoạt động, ONOS thực hiện điều khiển mạng thông qua hai giao diện chính là giao diện hướng Nam (Southbound Interface) và giao diện hướng Bắc (Northbound Interface).

Trước hết, ở giao diện hướng Nam, ONOS sử dụng giao thức OpenFlow để thiết lập và duy trì kết nối với các thiết bị Switch trong mạng. Khi một gói tin mới đi vào hệ thống nhưng không khớp với bất kỳ luật luồng (flow rule) nào đã tồn tại trong bảng luồng của Switch, thiết bị sẽ đóng gói thông tin của gói tin đó vào bản tin Packet-In và gửi lên Controller. Sau khi tiếp nhận yêu cầu, ONOS tiến hành phân tích trạng thái mạng, tính toán đường đi phù hợp và đưa ra quyết định xử lý. Tiếp theo, Controller gửi bản tin Packet-Out kèm theo các lệnh Flow Mod xuống Switch nhằm cập nhật bảng luồng và thiết lập cơ chế chuyển tiếp gói tin tương ứng.

Bên cạnh đó, giao diện hướng Bắc cung cấp tập RESTful API cho phép các ứng dụng bên ngoài tương tác trực tiếp với hệ thống mạng. Trong đề án này, các module thu thập dữ liệu và RL Agent liên tục khai thác các API của ONOS để thu thập thông tin thống kê theo thời gian thực, bao gồm tốc độ gói tin (packet rate), tốc độ byte (byte rate), số lượng flow và tỷ lệ mất gói (drop rate). Thông qua quá trình này, mô

2.3. MẠNG KHẢ LẬP TRÌNH - SOFTWARE DEFINED NETWORKING

hình AI có thể quan sát toàn bộ trạng thái mạng, từ đó tự động đưa ra các quyết định điều khiển và phối hợp với Controller để triển khai các chính sách bảo mật một cách linh hoạt và thích nghi với các tình huống tấn công mạng khác nhau.

2.3.3 Các loại tấn công trong SDN

Trong hệ thống Software Defined Networking (SDN), do đặc điểm tách biệt giữa *Control Plane* và *Data Plane*, mạng trở thành mục tiêu của nhiều dạng tấn công khác nhau. Các cuộc tấn công này chủ yếu khai thác vào bộ điều khiển, luồng dữ liệu và các giao diện API, gây ảnh hưởng nghiêm trọng đến hiệu suất và bảo mật hệ thống.

2.3.3.1 Tấn công Từ chối dịch vụ phân tán (DDoS)

- **Cơ chế tấn công:** Tấn công từ chối dịch vụ phân tán (DDoS) là hình thức nhằm làm gián đoạn hệ thống mạng bằng cách làm quá tải tài nguyên xử lý. Trong mạng SDN, cơ chế xử lý tập trung khiến hệ thống dễ bị tổn thương khi một lượng lớn gói tin mới đi vào switch mà chưa có quy tắc xử lý (flow rule). Lúc này, switch buộc phải gửi yêu cầu lên Controller, làm tăng đáng kể thời gian phản hồi. Kẻ tấn công có thể lợi dụng đặc điểm này để phân tích thời gian phản hồi (nhằm dò tìm sự tồn tại của SDN), sau đó huy động mạng lưới botnet gửi lượng lớn gói tin giả mạo. Việc này buộc switch liên tục gửi request, gây quá tải tài nguyên (CPU, RAM) của Controller, làm sai lệch luồng dữ liệu và khiến toàn bộ dịch vụ bị chậm hoặc ngừng hoạt động hoàn toàn.
- **Cách phòng chống:** Để đối phó với DDoS, hệ thống SDN cần áp dụng cơ chế phân tích hành vi thiết lập kết nối và lưu lượng gói tin trực tiếp từ lớp ứng dụng trên Controller. Giải pháp tiêu biểu là phân loại người dùng dựa trên cơ sở dữ liệu địa chỉ IP tin cậy IP Address Database (IAD). Người dùng sẽ được phân thành các nhóm: nhóm hợp lệ (thuộc IAD, số lượng kết nối và định mức gói tin trong ngưỡng an toàn), nhóm bị lợi dụng hoặc zombie (thuộc IAD nhưng gửi request dị thường, gói tin rỗng), và nhóm chưa định danh mang hành vi độc hại. Dựa vào phân loại này, khi nhận được yêu cầu xử lý từ Switch, Controller sẽ đánh giá IP nguồn. Nếu hợp lệ, hệ thống thiết lập luồng bình thường; nếu

bất thường, Controller lập tức sử dụng OpenFlow để đẩy luật xuống Switch nhằm hạn chế băng thông hoặc chặn đứt kết nối.

2.3.3.2 Tấn công cạn kiệt tài nguyên Controller (Packet-In Flood)

- **Cơ chế tấn công:** Là một biến thể nguy hiểm nhắm thẳng vào "điểm mù" của giao tiếp OpenFlow. Khi kẻ tấn công liên tục tạo ra các gói tin với tiêu đề (IP, MAC, Port) thay đổi ngẫu nhiên, Switch sẽ không thể tìm thấy luật khớp trong bảng luồng. Theo cơ chế mặc định, Switch phải đóng gói toàn bộ lượng gói tin khổng lồ này vào bản tin *Packet-In* và gửi lên Controller. Việc này tạo ra hiện tượng "nút thắt cổ chai" tại giao diện hướng Nam, đồng thời làm cạn kiệt năng lực xử lý tính toán của bộ điều khiển trung tâm.
- **Cách phòng chống:** Giải pháp phòng vệ hiệu quả là thiết lập Rate-limiting ngay tại các cổng của Switch. Bên cạnh đó, Controller có thể được tích hợp các mô hình Học máy (Machine Learning) để nhận diện nhanh các mẫu lưu lượng ngẫu nhiên bất thường. Khi phát hiện, Controller chủ động đẩy xuống Switch một luật xử lý chung (wildcard rule) với độ ưu tiên thấp để tự động loại bỏ các gói tin dị thường này ở lớp dữ liệu mà không cần truy vấn lại lên lớp điều khiển.

2.3.3.3 Tấn công tràn bảng luồng (Flow Table Overflow)

- **Cơ chế tấn công:** Switch trong SDN sử dụng bộ nhớ TCAM để lưu trữ các quy tắc định tuyến. Tuy có tốc độ truy xuất cực nhanh nhưng dung lượng TCAM lại rất hạn chế. Bằng cách sử dụng các công cụ tạo lưu lượng với địa chỉ IP nguồn giả mạo liên tục, tin tặc ép Controller phải sinh ra hàng ngàn luật mới cho mỗi kết nối "ảo" đó. Khi bộ nhớ TCAM bị lấp đầy bởi các luật rác, Switch sẽ mất khả năng tiếp nhận thêm luật cho các luồng dữ liệu hợp pháp của hệ thống.
- **Cách phòng chống:** Controller cần quản lý chặt chẽ vòng đời của các luật bằng cách cấu hình thời gian sống (Hard Timeout và Idle Timeout) hợp lý để nhanh chóng xóa bỏ các luồng không còn hoạt động. Hệ thống cũng có thể

2.3. MẠNG KHẢ LẬP TRÌNH - SOFTWARE DEFINED NETWORKING

áp dụng các cơ chế thu hồi chủ động (Active Eviction) khi bộ nhớ đạt ngưỡng báo động, hoặc sử dụng luật định tuyến gộp (aggregation rules) để tối ưu hóa không gian lưu trữ của bảng luồng.

2.3.3.4 Tấn công giả mạo luồng dữ liệu (Traffic & IP Spoofing)

- **Cơ chế tấn công:** Tấn công giả mạo luồng (Traffic Spoofing) là hình thức tạo ra các gói tin giả nhằm đánh lừa các thành phần mạng (Switch, Controller, Ứng dụng). Kẻ tấn công có thể giả mạo địa chỉ IP nguồn (IP Spoofing) hoặc giả mạo danh tính của thiết bị mạng để qua mặt các danh sách điều khiển truy cập (ACL). Hành vi này làm sai lệch định tuyến, mất kiểm soát luồng dữ liệu và thường là bước đệm mở đường cho các cuộc tấn công lớn hơn như Tấn công trung gian (Man-In-The-Middle) hay DoS.
- **Cách phòng chống:** Tận dụng tầm nhìn toàn cục (global view) của SDN, Controller có thể đối phó với giả mạo luồng bằng cách duy trì bảng ánh xạ nghiêm ngặt giữa địa chỉ MAC, IP và cổng vật lý (MAC-IP-Port Binding). Ngoài ra, hệ thống cần tích hợp các Hệ thống phát hiện xâm nhập (IDS) phân tích hành vi truy cập kết hợp cơ chế kiểm tra đường dẫn ngược (uRPF - Unicast Reverse Path Forwarding) để tự động phát hiện và loại bỏ các gói tin xuất phát từ những vị trí không hợp lệ.

2.3.3.5 Tấn công dò quét và rò rỉ thông tin (Information Disclosure & Scanning)

- **Cơ chế tấn công:** Dạng tấn công này nhằm thu thập thông tin nhạy cảm và lập bản đồ kiến trúc mạng của mục tiêu. Bằng cách sử dụng các công cụ như Nmap để rà quét dồn dập các cổng dịch vụ (Port Scanning) hoặc nghe lén (Sniffing) dữ liệu truyền qua mạng, kẻ tấn công có thể xác định được hệ điều hành, mật khẩu, lỗ hổng trong giao thức (ví dụ OpenFlow không mã hóa) và cấu trúc ứng dụng. Mặc dù không trực tiếp gây gián đoạn mạng, đây là bước trình sát vô cùng nguy hiểm chuẩn bị cho các đợt xâm nhập chí mạng.
- **Cách phòng chống:** Để bảo mật thông tin, toàn bộ dữ liệu trao đổi giữa

Switch và Controller cần được mã hóa thông qua chuẩn TLS/SSL. Bên cạnh đó, Controller có thể phát hiện hành vi quét cổng bằng cách theo dõi sự gia tăng đột biến của các bản tin TCP RST hoặc kết nối ICMP thất bại. Khi phát hiện trình sát, hệ thống có thể tạm thời khóa IP nguồn, hoặc điều hướng lưu lượng của kẻ tấn công vào mạng lưới bẫy (Honeypot) để đánh lừa và phân tích thủ đoạn của chúng.

2.3.4 Các phương pháp phòng vệ truyền thống

Trước những nguy cơ tấn công trong mạng Software Defined Networking (SDN), việc triển khai các cơ chế bảo mật phù hợp là rất cần thiết. Các giải pháp phòng vệ cần được áp dụng đồng bộ trên nhiều lớp của kiến trúc SDN nhằm đảm bảo tính toàn vẹn, bảo mật và khả năng hoạt động ổn định của hệ thống.

2.3.4.1 Phòng chống tấn công DDoS

Để giảm thiểu tác động của các cuộc tấn công DDoS vào SDN Controller và hệ thống mạng, có thể áp dụng các biện pháp sau:

- **Giới hạn tốc độ (Rate Limiting):** Hạn chế số lượng request từ switch gửi đến controller trong một khoảng thời gian nhất định nhằm tránh quá tải.
- **Phân tích và phát hiện lưu lượng bất thường:** Sử dụng các thuật toán phân tích lưu lượng để phát hiện các hành vi bất thường và phân loại người dùng (hợp lệ, zombie,...).
- **Cơ chế xác thực và kiểm soát truy cập:** Chỉ cho phép các thiết bị và người dùng hợp lệ gửi yêu cầu đến controller.
- **Cân bằng tải controller:** Triển khai nhiều controller (*distributed controller*) để tránh điểm lỗi đơn và giảm áp lực xử lý.

2.3.4.2 Phòng chống giả mạo luồng (Spoofing Attack)

Để ngăn chặn các cuộc tấn công giả mạo trong SDN, cần:

2.3. MẠNG KHẢ LẬP TRÌNH - SOFTWARE DEFINED NETWORKING

- **Xác thực thiết bị và thành phần mạng:** Sử dụng cơ chế xác thực mạnh (TLS, certificate) giữa controller và switch.
- **Kiểm tra tính hợp lệ của gói tin:** Áp dụng các kỹ thuật lọc gói tin và kiểm tra nguồn gửi.
- **Triển khai hệ thống phát hiện xâm nhập (IDS/IPS):** Giúp phát hiện và ngăn chặn các hành vi bất thường trong mạng.
- **Bảo vệ API:** Áp dụng cơ chế xác thực, phân quyền và mã hóa cho Northbound và Southbound API.

2.3.4.3 Phòng chống rò rỉ thông tin (Information Disclosure)

Để đảm bảo an toàn dữ liệu trong SDN, cần thực hiện:

- **Mã hóa dữ liệu:** Sử dụng các giao thức bảo mật như TLS/SSL để mã hóa dữ liệu truyền giữa các thành phần.
- **Bảo mật giao thức:** Cấu hình an toàn cho các giao thức như OpenFlow, tránh truyền dữ liệu dạng *plaintext*.
- **Kiểm soát truy cập dữ liệu:** Giới hạn quyền truy cập vào thông tin nhạy cảm.
- **Giám sát và ghi log:** Theo dõi hoạt động mạng để phát hiện sớm các hành vi truy cập trái phép.

2.3.4.4 Bảo mật SDN Controller

Do controller là thành phần quan trọng nhất trong SDN, cần áp dụng các biện pháp bảo vệ đặc biệt:

- **Cập nhật và vá lỗi hệ thống:** Đảm bảo hệ điều hành và phần mềm controller luôn được cập nhật.
- **Thay đổi mật khẩu mặc định:** Sử dụng mật khẩu mạnh và cơ chế xác thực đa yếu tố (MFA).
- **Phân quyền quản trị:** Giới hạn quyền truy cập theo vai trò người dùng.

- **Triển khai controller phân tán:** Giảm nguy cơ bị tấn công tập trung vào một điểm duy nhất.

2.3.4.5 Tổng kết giải pháp phòng vệ

Các giải pháp bảo mật trong SDN cần được triển khai đồng thời trên nhiều lớp:

- Lớp hạ tầng: bảo vệ thiết bị mạng
- Lớp điều khiển: bảo vệ controller
- Lớp ứng dụng: bảo vệ API và dịch vụ

Việc kết hợp nhiều cơ chế như xác thực, mã hóa, giám sát và phân tích lưu lượng sẽ giúp nâng cao khả năng phòng chống tấn công và đảm bảo an toàn cho hệ thống SDN.

2.3.5 Các chỉ số đánh giá hệ thống mạng

Để đánh giá hiệu quả của các mô hình điều khiển và giải pháp bảo mật trong môi trường SDN, các chỉ số về chất lượng dịch vụ và hiệu suất vận hành là thước đo quan trọng nhất. Trong đồ án này, hệ thống được đánh giá dựa trên các nhóm chỉ số chính sau:

- **Thông lượng (Throughput):** Là lượng dữ liệu được truyền tải thành công từ nguồn đến đích trong một đơn vị thời gian (thường tính bằng Mbps hoặc Gbps). Trong kịch bản tấn công DDoS, thông lượng của người dùng hợp lệ thường bị sụt giảm nghiêm trọng. Một hệ thống phòng thủ tốt phải duy trì được thông lượng ổn định cho lưu lượng sạch ngay cả khi đang xảy ra tấn công.
- **Độ trễ (Latency/Delay):** Khoảng thời gian cần thiết để một gói tin đi từ nguồn đến đích. Trong SDN, độ trễ bao gồm trễ truyền dẫn trên đường truyền và trễ xử lý tại Controller khi thiết lập luồng mới (Packet-In processing). Tấn công Flood làm tăng hàng đợi tại Switch và quá tải CPU của Controller, dẫn đến độ trễ tăng vọt.

2.4. CÁC NGHIÊN CỨU LIÊN QUAN

- **Tỷ lệ mất gói (Packet Loss Rate):** Tỷ lệ phần trăm số gói tin bị mất so với tổng số gói tin được gửi đi. Chỉ số này phản ánh mức độ nghẽn mạng hoặc tác động tiêu cực của các cuộc tấn công tràn bảng luồng (Flow Table Overflow), khi Switch không còn không gian lưu trữ luật xử lý và buộc phải loại bỏ các gói tin mới.
- **Độ biến động trễ (Jitter):** Sự thay đổi về khoảng thời gian trễ giữa các gói tin liên tiếp trong cùng một luồng dữ liệu. Jitter cao gây ảnh hưởng tiêu cực đến các dịch vụ thời gian thực như VoIP hoặc Video Streaming.
- **Tỷ lệ sử dụng tài nguyên (Resource Utilization):** Bao gồm mức độ chiếm dụng CPU, RAM của SDN Controller và dung lượng bộ nhớ TCAM trên các thiết bị Switch. Một hệ thống RL tối ưu cần đưa ra quyết định mà không làm tiêu tốn quá nhiều tài nguyên tính toán của bộ điều khiển trung tâm.
- **Giá trị phần thưởng (Reward Value):** Đây là chỉ số đặc thù trong Học máy tăng cường, phản ánh mức độ hội tụ của tác tử AI. Hàm phần thưởng được thiết kế dựa trên sự kết hợp giữa việc tối ưu hóa QoS và hiệu quả ngăn chặn tấn công, giúp đánh giá khả năng "học" của mô hình qua các tập (episodes).

Việc phân tích đồng bộ các chỉ số này giúp đưa ra cái nhìn toàn diện về sự cân bằng (trade-off) giữa tính bảo mật và trải nghiệm người dùng trong hệ thống mạng khả lập trình.

2.4 Các nghiên cứu liên quan

Trong những năm gần đây, sự phát triển của mạng khả lập trình (Software-Defined Networking – SDN) cùng với sự gia tăng của các thiết bị IoT đã mở rộng đáng kể bề mặt tấn công mạng. Các phương pháp bảo mật truyền thống dần bộc lộ hạn chế trong việc đối phó với các cuộc tấn công hiện đại như DDoS, DoS hay các hình thức tấn công mới. Do đó, nhiều nghiên cứu đã tập trung vào việc ứng dụng Machine Learning (ML) và đặc biệt là Reinforcement Learning (RL) để xây dựng các hệ thống phòng vệ thông minh và thích nghi.

2.4.1 Ứng dụng RL trong SDN

RL là một nhánh của học máy cho phép agent học cách ra quyết định tối ưu thông qua tương tác với môi trường. Trong bối cảnh SDN, RL được xem là một giải pháp hiệu quả nhờ khả năng tận dụng tầm nhìn toàn cục của controller và dữ liệu mạng theo thời gian thực. RL được áp dụng trong SDN nhằm tối ưu hóa việc điều khiển mạng thông qua ba thành phần chính:

- **State (Trạng thái):** bao gồm các chỉ số như độ trễ (latency), thông lượng (throughput), jitter và lưu lượng mạng
- **Action (hành động):** điều chỉnh băng thông, chuyển hướng luồng hoặc giữ nguyên trạng thái
- **Reward (phần thưởng):** phản ánh chất lượng dịch vụ (QoS), thường dựa trên độ trễ và jitter

Các thuật toán RL phổ biến được sử dụng trong SDN bao gồm:

- Q-Learning
- Deep Q-Network (DQN)
- Double Deep Q-Network (DDQN)
- Proximal Policy Optimization (PPO)

Trong đó, DDQN được đánh giá cao vì khả năng giảm hiện tượng overestimation, giúp quá trình học ổn định hơn. Ngoài ra, nhiều nghiên cứu khác như DRL-QOR (IEEE TNSM) [8] và Meta-ATMOS+ (IEEE) [9] cũng đã chứng minh rằng RL có thể tối ưu hóa tài nguyên mạng và cải thiện QoS trong môi trường SDN phức tạp. Điều này cho thấy RL đang trở thành xu hướng chính trong việc xây dựng hệ thống mạng tự động và thông minh.

2.4.2 RL trong phát hiện và giảm thiểu tấn công mạng

Các phương pháp truyền thống như rule-based hoặc Machine Learning (ML) thường gặp khó khăn trong việc xử lý các cuộc tấn công mới hoặc biến đổi. Trong khi đó,

2.4. CÁC NGHIÊN CỨU LIÊN QUAN

RL có khả năng học và thích nghi với môi trường động, giúp nâng cao hiệu quả phát hiện và giảm thiểu tấn công.

2.4.2.1 Phương pháp ML/DL truyền thống

Các nghiên cứu sử dụng:

- Random Forest
- Support Vector Machine (SVM)
- Convolutional Neural Network (CNN)

Cho thấy khả năng phát hiện tấn công tương đối tốt. Tuy nhiên, các phương pháp này có một số hạn chế:

- Phụ thuộc vào dữ liệu huấn luyện có nhãn
- Không có khả năng ra quyết định xử lý
- Khó thích nghi với các tấn công mới

2.4.2.2 Reinforcement Learning trong mitigation

Nghiên cứu QoSentry [1] đề xuất sử dụng thuật toán DDQN để giảm thiểu tấn công DDoS trong SDN. Agent RL học cách:

- Giảm thiểu băng thông của traffic độc hại
- Chuyển hướng traffic hợp lệ
- Duy trì chất lượng dịch vụ cho người dùng

Kết quả thực nghiệm cho thấy:

- Throughput hợp lệ tăng đáng kể (600 kbps)
- Độ trễ và jitter giảm
- Hệ thống thích nghi tốt với nhiều mức độ tấn công

2.4.3 So sánh với các phương pháp truyền thống

Các phương pháp bảo mật mạng hiện nay có thể được phân loại thành ba nhóm chính, tương ứng với mức độ linh hoạt và khả năng thích nghi khác nhau trong quá trình phát hiện và ứng phó với tấn công.

2.4.3.1 Rule-based

Nhóm phương pháp Rule-based dựa trên tập luật cố định. Cách tiếp cận này có ưu điểm là đơn giản, dễ triển khai và phù hợp với các kịch bản tấn công đã biết. Tuy nhiên, do phụ thuộc vào các ngưỡng và luật cố định, phương pháp này khó thích nghi với các hình thức tấn công mới hoặc các biến thể chưa từng xuất hiện trong quá khứ.

2.4.3.2 Machine Learning / Deep Learning

Nhóm phương pháp Machine Learning và *Deep Learning* có khả năng học các mẫu đặc trưng từ dữ liệu, từ đó hỗ trợ phát hiện bất thường hoặc phân loại tấn công với độ chính xác cao hơn so với phương pháp dựa trên luật. Tuy nhiên, các mô hình này chủ yếu tập trung vào bài toán nhận diện, chưa trực tiếp tối ưu hóa hành động phản ứng của hệ thống sau khi phát hiện tấn công. Ngoài ra, hiệu quả của mô hình phụ thuộc mạnh vào chất lượng và tính đại diện của dữ liệu huấn luyện.

2.4.3.3 Reinforcement Learning

Khác với hai nhóm phương pháp trên, Reinforcement Learning cho phép hệ thống học thông qua tương tác trực tiếp với môi trường và tối ưu hóa chính sách ra quyết định dựa trên phần thưởng nhận được. Cách tiếp cận này không chỉ hỗ trợ học trực tuyến mà còn cho phép tác tử thích nghi với các trạng thái mạng thay đổi theo thời gian. Nhờ đó, Reinforcement Learning đặc biệt phù hợp với các bài toán phòng thủ mạng SDN, nơi hệ thống cần vừa phát hiện, vừa lựa chọn hành động phản ứng tối ưu trong điều kiện môi trường động.

Từ bảng 2.1 trên, có thể thấy RL là phương pháp phù hợp nhất cho môi trường SDN động và phức tạp

2.4. CÁC NGHIÊN CỨU LIÊN QUAN

Tiêu chí	Rule-based	ML/DL	RL
Thích nghi	Thấp	Trung bình	Cao
Phát hiện tấn công mới	Thấp	Trung bình	Cao
Ra quyết định	Không	Không	Có
Tối ưu QoS	Không	Hạn chế	Tốt
Hoạt động thời gian thực	Hạn chế	Trung bình	Tốt

Bảng 2.1. Bảng so sánh tổng hợp các phương pháp bảo mật SDN.

2.4.4 Nhận xét và khoảng trống trong nghiên cứu

Từ các nghiên cứu đã trình bày, có thể rút ra một số nhận xét:

2.4.4.1 Ưu điểm chung

- RL giúp nâng cao khả năng thích nghi của hệ thống
- SDN cung cấp môi trường lý tưởng để triển khai RL
- Các phương pháp mới cải thiện QoS và giảm tác động của tấn công

2.4.4.2 Hạn chế

- Nhiều nghiên cứu chỉ dừng ở mức mô phỏng, chưa triển khai thực tế
- Thiếu đánh giá về độ ổn định của hệ thống (stability)
- Thiết kế hàm reward chưa phản ánh đầy đủ QoS và security

2.4.4.3 Khoảng trống nghiên cứu

Từ các hạn chế đã phân tích, có thể nhận thấy một số khoảng trống nghiên cứu đáng chú ý trong lĩnh vực phòng thủ mạng SDN dựa trên học tăng cường. Trước hết, nhiều công trình hiện nay mới tập trung vào một số khâu riêng lẻ như phát hiện bất thường hoặc phân loại tấn công, trong khi chưa xây dựng được một quy trình RL hoàn chỉnh bao gồm quan sát trạng thái, ra quyết định và thực thi hành động phòng thủ trong cùng một vòng lặp điều khiển. Bên cạnh đó, vấn đề cân bằng giữa hiệu quả bảo mật và chất lượng dịch vụ (QoS) vẫn chưa được xem xét đầy đủ trong quá trình thiết kế chính sách. Ngoài ra, số lượng nghiên cứu triển khai và đánh giá thực nghiệm trên các bộ điều khiển SDN thực tế như ONOS còn tương đối hạn chế.

2.4.4.4 Định hướng của đề tài

Trên cơ sở các khoảng trống nghiên cứu nêu trên, đề tài được định hướng theo các mục tiêu chính sau:

- Xây dựng mô hình học tăng cường áp dụng cho bài toán phòng thủ mạng SDN.
- Tích hợp đồng thời chức năng phát hiện và giảm thiểu tấn công trong một cơ chế ra quyết định thống nhất.
- Đánh giá hiệu năng của hệ thống dựa trên cả tiêu chí bảo mật, chất lượng dịch vụ (QoS) và độ ổn định của chính sách điều khiển.
- Triển khai và kiểm chứng mô hình trên môi trường thực nghiệm gồm ONOS và Mininet nhằm tăng tính khả thi và giá trị ứng dụng thực tiễn.

Chương 3. MÔ HÌNH BÀI TOÁN

Trong chương này, bài toán bảo mật mạng định nghĩa bằng phần mềm (Software Defined Networking – SDN) được mô hình hóa dưới dạng quy trình ra quyết định Markov (Markov Decision Process – MDP). Đây là cơ sở toán học quan trọng để áp dụng các thuật toán học tăng cường (Reinforcement Learning – RL), hướng đến xây dựng một hệ thống phòng thủ tự động có khả năng quan sát, ra quyết định và thích nghi với các trạng thái mạng khác nhau.

Quá trình tương tác giữa agent và môi trường mạng SDN diễn ra theo từng bước thời gian. Tại thời điểm t , agent đóng vai trò là thành phần ra quyết định được tích hợp với bộ điều khiển SDN. Agent quan sát trạng thái hiện tại của mạng, lựa chọn hành động phòng thủ phù hợp, sau đó nhận lại tín hiệu phản hồi dưới dạng phần thưởng để đánh giá chất lượng của hành động đã thực hiện.

Cụ thể, mô hình bài toán được xây dựng dựa trên ba thành phần chính của MDP, bao gồm:

3.1 Không gian trạng thái (State Space)

Không gian trạng thái mô tả tập hợp các đặc trưng đầu vào phản ánh tình trạng hiện tại của hệ thống mạng SDN. Trong mô hình đề xuất, để agent có cái nhìn toàn diện và chính xác nhất về tình trạng an ninh cũng như hiệu năng của mạng, trạng thái được biểu diễn dưới dạng một **State Vector** gồm 9 thành phần:

- Packet Rate (Tốc độ gói tin)
- Byte Rate (Tốc độ dữ liệu)
- Flow Count (Số lượng luồng)
- Source IP Entropy (Độ phân tán địa chỉ IP nguồn)
- Latency (Độ trễ mạng)
- Packet Loss (Tỷ lệ rơi gói)
- Queue Length (Độ dài hàng đợi trên Switch)

- Controller CPU (Mức tiêu thụ CPU của bộ điều khiển)
- Previous Action (Hành động ở bước trước đó)

Tất cả các đặc trưng này đều được chuẩn hóa (đưa về khoảng giá trị $[0, 1]$) nhằm đảm bảo tính đồng nhất về mặt toán học và giúp quá trình huấn luyện mạng nơ-ron ổn định hơn. Chi tiết về các thành phần như sau:

3.1.1 Packet Rate

Packet Rate (tốc độ gói tin) là số lượng gói tin được chuyển tiếp qua Switch trong một đơn vị thời gian. Thông số này được tính bằng cách tổng hợp số lượng gói tin (packets) từ tất cả các luồng (flows) đang hoạt động trên Switch.

Đây là một đặc trưng quan trọng trong việc phát hiện các bất thường về lưu lượng. Trong các kịch bản tấn công như DDoS, Ping Flood hoặc Packet-In Flood, Packet Rate thường tăng đột biến trong thời gian ngắn. Nhờ đó, agent có thể nhanh chóng nhận diện dấu hiệu bất thường và đưa ra phản ứng phù hợp.

Để đảm bảo tính ổn định trong quá trình huấn luyện, thông số này được chuẩn hóa:

- Đối với môi trường **online**: chia cho 10^6 .
- Đối với môi trường **offline**: chia theo ngưỡng 20000.

Sau khi chuẩn hóa, giá trị này được đưa vào vector trạng thái của agent.

3.1.2 Byte Rate

Byte Rate (tốc độ dữ liệu) biểu thị tổng khối lượng dữ liệu (tính theo byte) được truyền qua thiết bị mạng trong một đơn vị thời gian. Giá trị này được tính bằng cách tổng hợp số byte từ tất cả các rule luồng đang hoạt động trên Switch. Thông số này giúp phản ánh chính xác mức độ sử dụng băng thông của hệ thống. Khi kết hợp với Packet Rate, agent có thể phân biệt các loại lưu lượng khác nhau, ví dụ:

- Lưu lượng hợp lệ với kích thước gói lớn (truyền file).
- Lưu lượng tấn công với số lượng lớn gói nhỏ (flooding).

3.1. KHÔNG GIAN TRẠNG THÁI (STATE SPACE)

Byte Rate cũng được chuẩn hóa để đưa về cùng thang đo:

- Đối với môi trường **online**: chia cho 10^9
- Đối với môi trường **offline**: chia theo ngưỡng 500000

3.1.3 Flow Count

Flow Count là tổng số lượng luồng đang hoạt động trên Switch tại thời điểm quan sát. Thông số này phản ánh mức độ phức tạp của bảng luồng và tải xử lý của thiết bị mạng. Khi hệ thống xuất hiện các cuộc tấn công, số lượng flow thường tăng nhanh do Switch phải xử lý liên tục các yêu cầu thiết lập luồng mới.

Đây là một đặc trưng quan trọng giúp agent nhận diện trạng thái quá tải của hệ thống mạng SDN. Giá trị Flow Count được chuẩn hóa về khoảng $[0, 1]$ trước khi đưa vào vector trạng thái nhằm đảm bảo tính ổn định trong quá trình huấn luyện.

3.1.4 Source IP Entropy

Source IP Entropy biểu diễn mức độ phân tán của địa chỉ IP nguồn trong lưu lượng mạng hiện tại. Nếu lưu lượng chủ yếu đến từ một số ít nguồn thì entropy thấp. Ngược lại, nếu lưu lượng xuất phát từ nhiều IP khác nhau thì entropy sẽ tăng cao.

Thông số này đặc biệt hữu ích trong việc phát hiện các cuộc tấn công như DDoS Flood, IP Spoofing hoặc Port Scanning, vì các hình thức tấn công này thường tạo ra phân bố địa chỉ IP bất thường.

Sau khi tính toán, giá trị entropy được chuẩn hóa về khoảng $[0, 1]$ trước khi đưa vào trạng thái của agent.

3.1.5 Latency

Latency là độ trễ mạng được đo trong quá trình truyền thông giữa các host trong topology SDN. Đây là một trong những chỉ số QoS quan trọng giúp đánh giá chất lượng hoạt động của hệ thống mạng.

Khi xảy ra tấn công hoặc khi cơ chế phòng thủ hoạt động chưa tối ưu, độ trễ mạng thường tăng lên đáng kể. Nhờ theo dõi Latency, agent có thể đánh giá tác động của các hành động giảm thiểu tấn công đối với hiệu năng toàn hệ thống.

Giá trị Latency được chuẩn hóa về khoảng $[0, 1]$ trước khi đưa vào vector trạng thái.

3.1.6 Packet Loss

Packet Loss là tỷ lệ gói tin bị mất trong quá trình truyền thông trên mạng. Đây là chỉ số phản ánh trực tiếp tình trạng nghẽn mạng hoặc suy giảm hiệu năng hệ thống.

Trong các kịch bản như DDoS Flood hoặc Packet-In Flood, số lượng lớn lưu lượng bất thường có thể làm Switch và Controller quá tải, dẫn đến hiện tượng rớt gói tăng cao.

Thông số Packet Loss được sử dụng để giúp agent đánh giá hiệu quả của cơ chế phòng thủ cũng như mức độ ổn định của mạng sau khi áp dụng các hành động giảm thiểu. Giá trị này được chuẩn hóa về khoảng $[0, 1]$.

3.1.7 Queue Length

Queue Length biểu diễn độ dài hàng đợi gói tin trên Switch tại thời điểm quan sát. Đây là đặc trưng phản ánh mức độ tắc nghẽn cục bộ của thiết bị mạng.

Khi lưu lượng tăng mạnh hoặc khi Controller chưa xử lý kịp các sự kiện Packet-In, hàng đợi tại Switch sẽ tăng lên nhanh chóng. Nếu Queue Length vượt ngưỡng cho phép, hệ thống có thể xuất hiện độ trễ cao và packet loss.

Nhờ đặc trưng này, agent có thể học được thời điểm cần thực hiện các hành động để giảm tải cho hệ thống mạng.

3.1.8 Controller CPU

Controller CPU biểu diễn mức sử dụng tài nguyên CPU của SDN Controller tại thời điểm quan sát. Trong kiến trúc SDN, Controller đóng vai trò trung tâm điều phối lưu lượng và quản lý flow rules, do đó mức tải CPU phản ánh trực tiếp trạng thái hoạt động của toàn hệ thống.

Thông số này giúp agent nhận diện tình trạng quá tải của Controller để đưa ra các quyết định phòng thủ phù hợp. Giá trị Controller CPU được chuẩn hóa về khoảng $[0, 1]$.

3.2. THU THẬP DỮ LIỆU VÀ XÂY DỰNG MÔI TRƯỜNG MẠNG

3.1.9 Previous Action


Previous Action là hành động mà agent đã thực hiện ở bước thời gian trước đó. Thành phần này được bổ sung vào vector trạng thái nhằm cung cấp ngữ cảnh lịch sử cho quá trình ra quyết định.

Việc đưa Previous Action vào trạng thái giúp hạn chế hiện tượng *action flapping*, tức là agent liên tục thay đổi giữa các hành động khác nhau gây mất ổn định cho hệ thống mạng.

Trong mô hình đề xuất, Previous Action được mã hóa dưới dạng giá trị số và chuẩn hóa về khoảng $[0, 1]$ trước khi đưa vào mạng nơ-ron.

3.2 Thu thập dữ liệu và xây dựng môi trường mạng

Xây dựng một môi trường mạng SDN mô phỏng dựa trên Mininet kết hợp với SDN Controller ONOS để thu thập dữ liệu phục vụ quá trình huấn luyện mô hình Reinforcement Learning.



Hình 3.1. Topology mạng SDN được sử dụng trong hệ thống đề xuất.

Topology mạng được thiết kế gồm ba Switch chính:

- **Switch s1:** Đóng vai trò Switch trung tâm tiếp nhận lưu lượng từ các host tấn

công và người dùng hợp lệ.

- **Switch s2:** Kết nối tới máy chủ nạn nhân.
- **Switch s3:** Kết nối tới Honeypot nhằm phục vụ cơ chế chuyển hướng lưu lượng độc hại.

Hệ thống bao gồm các host với chức năng như sau:

- **h1 – h6:** Các host tấn công, dùng để sinh lưu lượng độc hại.
- **h7:** Người dùng hợp lệ sinh lưu lượng bình thường.
- **h8:** Máy chủ nạn nhân cần được bảo vệ.
- **h9:** Honeypot dùng để chuyển hướng và cô lập lưu lượng độc hại.

Topology được thiết kế theo mô hình không vòng lặp nhằm đảm bảo tính ổn định trong quá trình mô phỏng. Các kết nối chính trong hệ thống bao gồm:

- s1 kết nối với s2 để tạo đường truyền chính giữa attacker và victim.
- s1 kết nối với s3 để hỗ trợ cơ chế chuyển hướng lưu lượng sang Honeypot.
- Không kết nối trực tiếp giữa s2 và s3 nhằm tránh tạo loop trong mạng.

Trong quá trình hoạt động, lưu lượng bình thường từ h7 sẽ được truyền trực tiếp tới victim thông qua tuyến s1 → s2. Đồng thời, các host h1 – h6 sẽ sinh các loại lưu lượng tấn công khác nhau nhằm mô phỏng các kịch bản bất thường trong môi trường SDN.

Trong quá trình mô phỏng, các chỉ số mạng như Packet Rate, Byte Rate, Flow Count, Queue Length, Latency, Packet Loss và Controller CPU sẽ được thu thập liên tục từ Switch và Controller thông qua các module giám sát.

Dữ liệu thu thập được sau đó sẽ được chuẩn hóa và đưa vào môi trường Reinforcement Learning để agent học cách lựa chọn các hành động phòng thủ phù hợp.

Khi phát hiện lưu lượng bất thường, agent có thể lựa chọn chuyển hướng lưu lượng độc hại sang Honeypot thông qua tuyến s1 → s3 nhằm giảm tải cho victim và duy trì tính ổn định của hệ thống mạng.

3.3 Không gian hành động - Action Space

Không gian hành động bao gồm tập hợp các phản ứng mà bộ điều khiển SDN có thể áp dụng nhằm xử lý các trạng thái của mạng. Trong mô hình này, không gian hành động được thiết kế dưới dạng rời rạc với 5 hành động.

3.3.1 No Action

No Action được lựa chọn khi hệ thống không phát hiện dấu hiệu bất thường rõ ràng trong mạng. Trong trường hợp này, RL Agent không thực hiện bất kỳ thay đổi nào đối với cấu hình mạng mà tiếp tục duy trì trạng thái vận hành hiện tại.

Cách tiếp cận này giúp duy trì tính ổn định của lưu lượng hợp lệ, hạn chế việc phát sinh các flow rule không cần thiết và giảm tải cho bộ điều khiển SDN trong quá trình vận hành.

3.3.2 Block Suspicious Flow

Block Suspicious Flow được sử dụng khi hệ thống xác định một luồng lưu lượng có dấu hiệu bất thường dựa trên các đặc trưng như tần suất xuất hiện, entropy địa chỉ IP nguồn hoặc hành vi tương đồng với các mẫu tấn công đã biết.

Khi đó, hệ thống sẽ cài đặt một flow rule có độ ưu tiên cao (Priority = 50000) nhằm chặn toàn bộ lưu lượng đến từ nguồn nghi vấn bằng cơ chế *Drop* tại switch. Luật điều khiển này thường có thời gian tồn tại ngắn nhằm đảm bảo khả năng phản ứng nhanh với tấn công nhưng vẫn hạn chế ảnh hưởng lâu dài đến hệ thống mạng.

3.3.3 Limit Bandwidth

Thay vì chặn hoàn toàn lưu lượng, Limit Bandwidth áp dụng cơ chế giới hạn băng thông thông qua *Meter Rule*. Hệ thống thiết lập một ngưỡng lưu lượng xác định; các gói tin vượt quá giới hạn này sẽ bị loại bỏ hoặc điều tiết.

Phương pháp này đặc biệt phù hợp trong các kịch bản tấn công DDoS, giúp giảm áp lực lên hạ tầng mạng trong khi vẫn duy trì khả năng giao tiếp tối thiểu cho các kết nối hợp lệ.

3.3.4 Redirect Traffic

Redirect Traffic được sử dụng để chuyển hướng lưu lượng đáng ngờ sang một môi trường phân tích thay vì chặn trực tiếp. Hệ thống sẽ cài đặt flow rule với độ ưu tiên (Priority = 45000) nhằm định tuyến traffic từ nguồn nghi vấn đến một cổng hoặc một môi trường riêng biệt như honeypot.

Cơ chế này cho phép thu thập dữ liệu tấn công, phân tích hành vi của attacker và giảm thiểu ảnh hưởng của lưu lượng độc hại lên hệ thống chính.

3.3.5 Isolate Device

Isolate Device là hành động phòng thủ mạnh nhất trong không gian hành động của hệ thống. Khi phát hiện thiết bị có mức độ nguy hiểm cao, hệ thống sẽ áp dụng flow rule với độ ưu tiên lớn nhất và thời gian tồn tại dài hơn nhằm cô lập hoàn toàn thiết bị bị nghi ngờ.

Toàn bộ lưu lượng từ thiết bị nguồn sẽ bị chặn để ngăn chặn triệt để quá trình tấn công, đồng thời hạn chế nguy cơ lan truyền sang các thành phần khác trong mạng.

3.4 Hàm thưởng - Reward Function

Hàm thưởng đóng vai trò định hướng quá trình học của agent, giúp tối ưu hóa các quyết định trong môi trường mạng. Giá trị reward tại mỗi bước được xây dựng dựa trên ba thành phần chính:

3.4.1 QoS Penalty

Thành phần QoS Penalty được sử dụng để phản ánh mức độ suy giảm chất lượng dịch vụ của hệ thống sau khi RL Agent thực hiện một hành động phòng thủ. Cụ thể, RL Agent sẽ bị trừ điểm thưởng khi các chỉ số vận hành của mạng có xu hướng xấu đi, bao gồm tỷ lệ mất gói tăng cao, độ trễ mạng lớn hoặc số lượng luồng bất thường tăng đột biến.

Cơ chế này nhằm đảm bảo rằng các hành động phòng thủ được lựa chọn không gây ảnh hưởng tiêu cực đến hiệu năng tổng thể của hệ thống, đặc biệt trong các tình huống lưu lượng hợp lệ vẫn cần được duy trì ổn định.

3.4. HÀM THUỞNG - REWARD FUNCTION

3.4.2 Security Reward

Thành phần Security Reward được thiết kế nhằm khuyến khích RL Agent đưa ra các hành động phù hợp với trạng thái an ninh hiện tại của mạng, dựa trên biến *attack indicator*. Khi hệ thống phát hiện dấu hiệu tấn công, các hành động phòng thủ thích hợp sẽ được cộng điểm thưởng, trong khi việc bỏ lơ tấn công hoặc không thực hiện bất kỳ phản ứng nào sẽ bị phạt.

Ngược lại, trong trường hợp hệ thống đang ở trạng thái bình thường, hành động *No Action* sẽ được khuyến khích, còn các phản ứng phòng thủ không cần thiết sẽ bị trừ điểm. Cách thiết kế này giúp cân bằng giữa hai mục tiêu: Bảo vệ hệ thống trước tấn công và hạn chế tác động không mong muốn lên lưu lượng hợp lệ.

3.4.3 Stability Penalty

Để hạn chế hiện tượng dao động chính sách và tránh việc thay đổi cấu hình mạng liên tục, hệ thống bổ sung thêm thành phần Stability Penalty. Thành phần này dựa trên hành động được thực hiện ở bước trước đó; nếu RL Agent thay đổi quyết định so với hành động trước, một mức phạt nhỏ sẽ được áp dụng.

Cơ chế này giúp giảm tình trạng *flapping* trong quá trình điều khiển, hạn chế quá tải cho switch và controller, đồng thời nâng cao tính ổn định của toàn bộ hệ thống phòng thủ.

Chương 4. PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày chi tiết về kiến trúc và phương pháp tiếp cận được nhóm đề xuất nhằm giải quyết bài toán tự động hóa phòng thủ trong mạng SDN. Nội dung chương sẽ đi sâu vào mô tả sơ đồ khối tổng thể của hệ thống, quá trình tương tác giữa môi trường dữ liệu mạng và AI Agent. Trọng tâm của chương là việc thiết kế các mô hình Học tăng cường, bao gồm cách thức định nghĩa không gian trạng thái, không gian hành động và hàm phần thưởng để tối ưu hóa chiến lược giảm thiểu tấn công. Bên cạnh đó, chương cũng sẽ làm rõ quy trình triển khai, đóng gói và giám sát hệ thống hiện đại, qua đó chứng minh tính toàn vẹn, khả năng mở rộng và mức độ sẵn sàng ứng dụng vào thực tiễn của giải pháp.

4.1 Kiến trúc hệ thống

Kiến trúc tổng thể của hệ thống được thiết kế theo mô hình vòng lặp tương tác khép kín Closed-Loop Interaction, cho phép hệ thống tự động theo dõi, học hỏi và ra quyết định phòng vệ liên tục trong mạng SDN. Luồng hoạt động của hệ thống được chia thành các phân hệ cốt lõi nối tiếp nhau, tạo thành một pipeline xử lý dữ liệu và huấn luyện tác tử AI hoàn chỉnh như sau:

- **Môi trường mạng và Thu thập dữ liệu (Network Environment & Data Collection):** Bắt đầu tại môi trường mạng SDN Network Environment, hệ thống bao gồm các thiết bị chuyển mạch OpenFlow kết nối với nhóm máy chủ tấn công, người dùng hợp lệ, máy chủ mục tiêu Victim và hệ thống Honey-pot. Khi lưu lượng mạng đi qua các switch, bao gồm cả các cuộc tấn công như DDoS Flood, Packet-In Flood hay IP Spoofing, phân hệ Monitoring Data Collection sẽ liên tục thu thập các chỉ số thống kê luồng Flow Statistics, giám sát gói tin, đo lường chất lượng dịch vụ QoS và mức độ tải của bộ điều khiển.
- **Khởi tạo không gian trạng thái (State Construction):** Dữ liệu đo lường thô sau đó sẽ trải qua giai đoạn State Construction để tổng hợp thành một vector trạng thái RL State 9 chiều đại diện cho tình trạng mạng tại thời điểm hiện tại. Vector này bao gồm các thông số quan trọng như tốc độ gói tin Packet Rate, tốc độ byte Byte Rate, số lượng luồng Flow Count, độ hỗn loạn IP nguồn (Source

4.1. KIẾN TRÚC HỆ THỐNG

IP Entropy), độ trễ (Latency), tỷ lệ mất gói (Packet Loss), chiều dài hàng đợi (Queue Length), mức sử dụng CPU của Controller và hành động ở bước trước đó (Previous Action). Việc đưa hành động trước đó vào trạng thái hiện tại giúp mô hình có thêm ngữ cảnh lịch sử, từ đó giảm thiểu hiện tượng thay đổi hành động liên tục không ổn định Action Flapping.

- **Tác tử RL và Cơ chế chọn hành động (RL Agent & Action Selection):**

Trạng thái 9 chiều này tiếp tục được đẩy vào trung tâm não bộ của hệ thống là RL Agent, nơi triển khai các thuật toán học tăng cường tiêu biểu như DQN hoặc PPO. Tại đây, mạng nơ-ron chính Policy Network sẽ tiến hành phân tích trạng thái và phối hợp cùng bộ nhớ kinh nghiệm (Experience Replay) để tính toán chiến lược, đồng thời cân bằng giữa quá trình khám phá Exploration và khai thác Exploitation. Kết quả của quá trình suy luận là bước Action Selection, trong đó tác tử quyết định chọn ra một hành động phòng thủ cụ thể thuộc (Action Space), bao gồm năm mức độ: không can thiệp (No Action), chặn luồng (Block Flow), giới hạn băng thông (Rate Limiting), định tuyến lại lưu lượng (Traffic Rerouting) hoặc cách ly thiết bị hoàn toàn (Device Isolation).

- **Thực thi phòng thủ và Phản hồi từ môi trường (Mitigation Execution & Environment Feedback):**


Hành động được tác tử lựa chọn ngay lập tức chuyển tới bước Mitigation Execution. SDN Controller ONOS sẽ biên dịch hành động này thành các chính sách và đẩy các luật định tuyến Flow Rules xuống các switch biên thông qua giao thức OpenFlow để thực thi chặn đứng tấn công. Ngay sau khi áp dụng luật mới, mạng SDN sẽ phản hồi lại thông qua bước Environment Feedback, cung cấp trạng thái mạng cập nhật, sự thay đổi về QoS và hiệu quả giảm thiểu tấn công của biện pháp vừa được triển khai.

- **Đánh giá phần thưởng và Vòng lặp học tập (Reward Calculation & Policy Update):**

Dựa trên phản hồi thực tế từ môi trường, phân hệ Reward Calculation sẽ tính toán giá trị phần thưởng để đánh giá tính đúng đắn của hành động. Hàm phần thưởng được thiết kế chặt chẽ dựa trên mức độ cải thiện QoS, khả năng giảm trừ tác động của tấn công, sự cải thiện về độ trễ và tỷ lệ mất gói, cũng như mức độ ổn định Network Stability. Cuối cùng, chuỗi dữ liệu giao

CHƯƠNG 4. PHƯƠNG PHÁP ĐỀ XUẤT

dịch Transition bao gồm trạng thái hiện tại, hành động đã chọn, phần thưởng nhận được và trạng thái kế tiếp sẽ được đưa vào giai đoạn Policy Update. Tại đây, mạng nơ-ron tiến hành huấn luyện tối thiểu hóa hàm mất mát Loss Minimization và cập nhật các trọng số chính sách. Toàn bộ quy trình này diễn ra liên tục qua nhiều chu kỳ, giúp tác tử không ngừng tiếp xúc thực tế và ngày càng hội tụ về một chiến lược phòng vệ tối ưu nhất.



Hình 4.1. Kiến trúc hệ thống đề xuất.

4.2 Multi-Seed Training

Để đảm bảo tính khách quan và khả năng hội tụ ổn định của mô hình, hệ thống triển khai quy trình Multi-seed Training. Mỗi thuật toán được huấn luyện song song với các giá trị hạt giống ngẫu nhiên khác nhau (3 seed cho DQN và 5 seed cho PPO) nhằm loại bỏ yếu tố may rủi và đánh giá độ lệch chuẩn của phần thưởng tích lũy.

4.3 Offline - Online Validation

4.3.1 Offline Validation

Giai đoạn Offline Validation được thực hiện nhằm đánh giá độ an toàn, tính ổn định và hiệu quả của các chính sách ra quyết định trước khi áp dụng vào môi trường mạng

4.3. OFFLINE - ONLINE VALIDATION

thực tế. Quá trình này giúp sàng lọc các tác nhân (Agent) hoạt động kém hiệu quả, ngăn chặn rủi ro gây sập mạng hoặc làm suy giảm nghiêm trọng chất lượng dịch vụ (QoS).

4.3.1.1 Chuẩn bị và tiền xử lý dữ liệu kiểm thử

Để quá trình kiểm chứng ngoại tuyến diễn ra khách quan, tập dữ liệu kiểm thử được xây dựng qua quy trình xử lý nghiêm ngặt từ các kịch bản mạng thô. Quá trình tiền xử lý bao gồm các bước sau:

- **Feature Imputation:** Các thông số hệ thống bị khuyết trong quá trình thu thập thô được nội suy dựa trên đặc tính của từng loại tấn công.
- **Min-Max Scaling:** Toàn bộ 8 đặc trưng mạng cốt lõi cùng nhãn tấn công (attack indicator) được chuẩn hóa về khoảng giá trị $[0, 1]$. Điều này giúp các thuật toán DQN, PPO xử lý dữ liệu ổn định và hội tụ nhanh hơn.
- **Stratified Split:** Dữ liệu sau chuẩn hóa được xáo trộn ngẫu nhiên và phân chia theo tỷ lệ 80% cho huấn luyện và 20% dành riêng cho kiểm thử Offline. Việc phân chia được thực hiện trên từng nhóm nhãn tấn công, đảm bảo tập kiểm thử phản ánh đầy đủ và cân bằng các mẫu lưu lượng của hệ thống.

4.3.1.2 Môi trường đánh giá Offline

Hệ thống sử dụng lớp môi trường giả lập `OfflineSDNEnv` được xây dựng dựa trên tập dữ liệu kiểm thử độc lập. Khác với môi trường trực tuyến, môi trường ngoại tuyến không tương tác trực tiếp với bộ điều khiển ONOS Controller. Thay vào đó, tái hiện lại các thay đổi trạng thái mạng bằng cách duyệt tuần tự qua các mẫu dữ liệu lịch sử.

4.3.1.3 Không gian trạng thái và hành động

Tại mỗi bước thời gian t , tác nhân nhận được một véc-tơ trạng thái quan sát $S_t \in \mathbb{R}^{10}$. Véc-tơ này bao gồm 9 đặc trưng đã được chuẩn hóa:

- **Các thông số lưu lượng:** Tốc độ gói tin (packet rate), băng thông (byte rate), số lượng luồng (flow count).

- **Chỉ số an ninh:** Entropy của IP nguồn (src ip entropy), nhãn tấn công (attack indicator).
- **Các thông số hệ thống và QoS:** Độ trễ (latency), tỷ lệ rớt gói (packet loss), độ dài hàng đợi (queue length), mức sử dụng CPU của bộ điều khiển.
- **Ngữ cảnh lịch sử:** Hành động đã thực hiện ở bước trước đó (previous action).

Dựa trên trạng thái S_t , tác nhân phải xuất ra một quyết định hành động $A_t \in \{0, 1, 2, 3, 4\}$. Các hành động này được ánh xạ lần lượt thành: Không can thiệp (No Action), Chặn luồng (Block), Giới hạn băng thông (Limit Bandwidth), Chuyển hướng lưu lượng (Redirect), và Cô lập thiết bị (Isolate).

4.3.1.4 Hàm phần thưởng đánh giá

Mỗi hành động của tác nhân trong môi trường ngoại tuyến sẽ được đánh giá thông qua một hàm phần thưởng tổng hợp. Hàm này được thiết kế để cân bằng giữa ba mục tiêu cốt lõi:

$$R = \omega_1 \cdot R_{security} - \omega_2 \cdot P_{QoS} - \omega_3 \cdot P_{stability} \quad (4.1)$$

Trong đó:

- **Phần thưởng bảo mật ($Reward_{security}$):** Khuyến khích hệ thống đưa ra hành động can thiệp ngay khi phát hiện dấu hiệu tấn công. Hệ thống áp dụng hình phạt nghiêm khắc nếu mô hình bỏ lọt tấn công (False Negative) hoặc thực hiện hành động phòng vệ sai lệch khi mạng đang ở trạng thái bình thường (False Positive).
- **Hình phạt suy giảm dịch vụ ($Penalty_{QoS}$):** Trừ điểm phần thưởng dựa trên sự gia tăng của tỷ lệ rớt gói, độ trễ mạng, mức độ quá tải hàng đợi và CPU nhằm đảm bảo các hành động phòng vệ không làm tê liệt mạng.
- **Hình phạt thiếu ổn định ($Penalty_{switching}$):** Áp dụng khi tác nhân liên tục thay đổi quyết định giữa các bước liên tiếp. Điều này nhằm hạn chế hiện tượng dao động, giúp chính sách mạng được duy trì ổn định.

4.3. OFFLINE - ONLINE VALIDATION

4.3.1.5 Các chỉ số đo lường hiệu năng

Để so sánh năng lực của các thuật toán học tăng cường (DQN, PPO) với phương pháp Rule-based Baseline, hai chỉ số chính được sử dụng bao gồm:

- **Tổng phần thưởng (Total/Average Reward):** Đo lường hiệu suất tổng thể của mô hình trong việc tối ưu hóa đồng thời tính an toàn và chất lượng dịch vụ của mạng xuyên suốt một chu kỳ thử nghiệm.
- **Tỷ lệ nhảy luật (Switching Rate):** Được tính bằng tỷ lệ phần trăm số lần tác nhân thay đổi hành động liên tiếp so với tổng số bước vận hành. Chỉ số này càng gần 0%, mô hình đưa ra quyết định càng nhất quán và đáng tin cậy.

4.3.2 Online Validation

Sau khi hoàn tất quá trình Offline Validation, hệ thống tiếp tục được đánh giá trong môi trường trực tuyến nhằm kiểm tra khả năng vận hành thực tế của các tác tử học tăng cường. Giai đoạn Online Validation cho phép đánh giá trực tiếp mức độ phản ứng, tính ổn định và hiệu quả giảm thiểu tấn công của hệ thống khi tương tác với hạ tầng SDN đang hoạt động.

4.3.2.1 Môi trường đánh giá Online

Hệ thống sử dụng lớp môi trường `OnlineSDNEnv` để tương tác trực tiếp với bộ điều khiển ONOS thông qua các API RESTful. Khác với môi trường Offline, trạng thái mạng trong môi trường trực tuyến được thu thập theo thời gian thực từ hệ thống SDN mô phỏng chạy trên Mininet.

Các thông số telemetry được cập nhật liên tục bao gồm lưu lượng mạng, số lượng flow, mức tải của controller, độ trễ và các chỉ số QoS khác. Dựa trên các trạng thái quan sát được, tác tử RL sẽ thực hiện suy luận chính sách và đưa ra quyết định phòng thủ phù hợp.

4.3.2.2 Không gian trạng thái và hành động

Trong môi trường Online Validation, tác tử tiếp tục sử dụng cùng không gian trạng thái và hành động như giai đoạn Offline nhằm đảm bảo tính nhất quán giữa quá trình

huấn luyện và triển khai thực tế.

Tại mỗi thời điểm t , tác nhân nhận được một véc-tơ trạng thái mạng đã được chuẩn hóa, bao gồm:

- Tốc độ gói tin (*packet rate*)
- Băng thông (*byte rate*)
- Số lượng luồng (*flow count*)
- Entropy IP nguồn (*src ip entropy*)
- Độ trễ mạng (*latency*)
- Tỷ lệ rớt gói (*packet loss*)
- Độ dài hàng đợi (*queue length*)
- Mức sử dụng CPU của bộ điều khiển (*controller CPU*)
- Hành động trước đó (*previous action*)

Dựa trên trạng thái quan sát được, tác tử sẽ xuất ra một hành động thuộc không gian hành động rời rạc:

- 0: No Action
- 1: Block
- 2: Limit Bandwidth
- 3: Redirect
- 4: Isolate

Các hành động này sau đó được ánh xạ thành các chính sách điều khiển mạng tương ứng và áp dụng trực tiếp lên hệ thống SDN thông qua ONOS Controller.

4.3.2.3 Cơ chế phản hồi và cập nhật trạng thái

Sau khi hành động được thực thi, hệ thống tiếp tục thu thập trạng thái mạng mới nhằm đánh giá tác động của chính sách vừa áp dụng. Các thay đổi về độ trễ, lưu lượng, packet loss, queue length và tải của controller sẽ được phản hồi lại cho tác tử dưới dạng trạng thái kế tiếp S_{t+1} .

Dựa trên phản hồi này, hệ thống tính toán phần thưởng tương ứng để đánh giá mức độ hiệu quả của hành động phòng thủ. Cơ chế phản hồi liên tục giúp tác tử thích nghi với sự thay đổi động của môi trường mạng và cải thiện chính sách điều khiển theo thời gian.

4.3.2.4 Các chỉ số đo lường hiệu năng

Trong môi trường Online Validation, hệ thống sử dụng các chỉ số sau để đánh giá hiệu quả hoạt động của các mô hình DQN và PPO:

- **Cumulative Reward:** Đánh giá hiệu suất tổng thể của tác tử trong quá trình vận hành trực tuyến.
- **Switching Rate:** Đo lường mức độ ổn định của chính sách thông qua tỷ lệ thay đổi hành động giữa các bước liên tiếp.
- **QoS Metrics:** Bao gồm độ trễ mạng (latency), tỷ lệ rớt gói (packet loss), độ dài hàng đợi và mức sử dụng CPU của controller.
- **Attack Mitigation Efficiency:** Đánh giá khả năng giảm thiểu tác động của các cuộc tấn công mạng lên hệ thống SDN.

Chương 5. CÀI ĐẶT VÀ THỰC NGHIỆM

Chương này trình bày chi tiết quá trình thiết lập môi trường mô phỏng, cấu hình các thuật toán học máy tăng cường và thiết lập các kịch bản thực nghiệm. Mục tiêu của chương là tạo ra một nền tảng thực nghiệm khách quan để đánh giá hiệu năng của các tác tử DQN và PPO trong việc quản lý an ninh mạng SDN.

5.1 Môi trường thực nghiệm và Triển khai

Kiến trúc mạng mô phỏng được xây dựng dựa trên nền tảng Mininet kết hợp với bộ điều khiển ONOS (Open Network Operating System). Để đảm bảo tính linh hoạt và khả năng mở rộng, toàn bộ hệ thống được đóng gói bằng công cụ Docker.

- **Cơ sở hạ tầng:** Sử dụng nền tảng K3s (Kubernetes) để quản lý các container service.
- **Giám sát hệ thống:** Tích hợp pipeline Prometheus và Grafana để thu thập và trực quan hóa các thông số mạng (throughput, latency, packet loss) theo thời gian thực.
- **Quản lý mô hình:** Sử dụng MLflow để theo dõi (tracking) các phiên huấn luyện, quản lý các siêu tham số và lưu trữ các biến thể của mô hình.

5.2 Cấu hình huấn luyện

Quá trình huấn luyện các tác tử được thiết lập dựa trên các thông số kỹ thuật cụ thể về không gian trạng thái, không gian hành động và hàm phần thưởng. Hệ thống được cài đặt huấn luyện cho hai mô hình DQN và PPO với các tham số như sau:

5.2.1 Thiết lập không gian Trạng thái và Hành động

Hệ thống giám sát mạng thông qua vector trạng thái 9 chiều ($n = 9$), cung cấp cái nhìn toàn diện về thực trạng lưu lượng:

- **State Space:** Bao gồm các chỉ số *packet_rate*, *byte_rate*, *flow_count*, *entropy* (địa chỉ IP/Port), *latency*, *packet_loss*, *queue_length*, *controller_cpu*, và *previous_action*.

5.3. THUẬT TOÁN VÀ THAM SỐ HUẤN LUYỆN

- **Action Space:** Tác tử có thể thực hiện 5 hành động phản ứng: *no_action* (0), *block* (1), *limit_bandwidth* (2), *redirect* (3), và *isolate* (4).

5.2.2 Hàm phần thưởng (Reward Function)

Hàm phần thưởng R được thiết kế dưới dạng hàm đa mục tiêu nhằm cân bằng giữa khả năng bảo mật và chất lượng dịch vụ:

$$R = \omega_1 \cdot R_{security} - \omega_2 \cdot P_{QoS} - \omega_3 \cdot P_{stability} \quad (5.1)$$

Trong đó:

- $R_{security}$: Thưởng khi ngăn chặn thành công các luồng độc hại.
- P_{QoS} : Hình phạt khi các hành động can thiệp gây ảnh hưởng tiêu cực đến người dùng hợp lệ.
- $P_{stability}$: Hình phạt nhằm hạn chế việc thay đổi hành động liên tục gây mất ổn định hệ thống (*Policy Flapping*).

5.3 Thuật toán và tham số huấn luyện

Để đảm bảo tính khách quan và độ tin cậy thống kê, hệ thống thực hiện huấn luyện đa giá trị khởi tạo (*Multi-seed training*) với 3 tham số khởi tạo cho DQN và 5 tham số khởi tạo cho PPO.

5.3.1 Thuật toán Deep Q-Network (DQN)

Tác tử DQN sử dụng cơ chế bộ đệm trải nghiệm và mạng đích để ổn định hóa quá trình học tập giá trị Q.

Algorithm 1: Huấn luyện DQN với đa giá trị khởi tạo ngẫu nhiên

Input: Tập tham số khởi tạo $\mathcal{S}$, Bộ đệm $\mathcal{B}$, Lịch trình ϵ

Output: Tham số tối ưu θ^* , Thống kê huấn luyện

```

1 for mỗi tham số khởi tạo  $s \in \mathcal{S}$  do
2     Thiết lập tham số khởi tạo  $s$  để đảm bảo tính tái lập;
3     for mỗi tập  $e = 1, \dots, M$  do
4         Khởi tạo trạng thái  $s_0$  và tổng thưởng  $R_e = 0$ ;
5         for mỗi bước  $t$  do
6             Chọn  $a_t$  theo chiến lược  $\epsilon$ -greedy;
7             Thực hiện  $a_t$ , quan sát  $r_t, s_{t+1}, d_t$  và lưu vào  $\mathcal{B}$ ;
8             if  $size(\mathcal{B}) > batch\_size$  then
9                 Lấy mẫu lô từ  $\mathcal{B}$  và cập nhật  $\theta$  bằng cách tối thiểu hóa MSE
10                Loss;
11                 $s_t \leftarrow s_{t+1}$  và  $R_e \leftarrow R_e + r_t$ ;
12                if  $d_t$  là đúng then
13                    break;
14         Cập nhật  $\epsilon$  và lưu thống kê tập;

```

Bảng 5.1. Siêu tham số cấu hình cho tác tử DQN

Tham số	Giá trị	Mục đích
LR	10^{-4}	Tốc độ học của mạng nơ-ron.
GAMMA	0, 95	Hệ số chiết khấu phần thưởng tương lai.
BATCH_SIZE	128	Kích thước mẫu dữ liệu cho mỗi lần cập nhật.
EPS_DECAY	4000	Tốc độ giảm dần của xác suất khám phá ϵ .

5.3.2 Thuật toán Proximal Policy Optimization (PPO)

Khác với DQN, thuật toán PPO sử dụng kiến trúc Actor–Critic kết hợp cơ chế PPO Clipped Objective nhằm ổn định quá trình cập nhật chính sách và hạn chế sự thay đổi đột ngột trong quá trình học. Phương pháp này giúp cải thiện khả năng hội tụ và tăng tính ổn định khi tác tử tương tác với môi trường SDN động.

5.4. PHƯƠNG PHÁP ĐÁNH GIÁ VÀ KỊCH BẢN THỬ NGHIỆM

Algorithm 2: Huấn luyện PPO với đa giá trị khởi tạo ngẫu nhiên

Input: Tập tham số khởi tạo $\mathcal{S}$, Mạng Actor-Critic π_θ, V_ϕ , Tỷ lệ cắt ϵ_{clip}

Output: Tham số tối ưu θ^*, ϕ^*

```

1 for mỗi tham số khởi tạo  $s \in \mathcal{S}$  do
2   for mỗi tập huấn luyện do
3     Thu thập tập trải nghiệm  $\{s_t, a_t, r_t\}$  bằng chính sách  $\pi_{\theta_{old}}$ ;
4     Tính lợi thế  $\hat{A}_t$  và chuẩn hóa;
5     for mỗi epoch cập nhật do
6       Tính tỉ lệ xác suất  $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ ;
7       Cập nhật  $\theta, \phi$  bằng cách tối đa hóa mục tiêu PPO Clipped;
8      $\theta_{old} \leftarrow \theta$ ;
```

Bảng 5.2. Siêu tham số cấu hình cho tác tử PPO

Tham số	Giá trị	Mục đích
LR_PPO	2×10^{-4}	Tốc độ học tối ưu của Actor-Critic.
clip_eps	0,15	Giới hạn cập nhật chính sách.
entropy_coef	0,02	Khuyến khích tác tử khám phá môi trường.
value_coef	0,5	Trọng số cho mất mát của mạng Critic (Value function).

5.4 Phương pháp đánh giá và Kịch bản thử nghiệm

5.4.1 Chỉ số đánh giá

Hiệu năng của các tác tử được đánh giá dựa trên các chỉ số định lượng sau:

- **Mean Reward:** Phần thưởng trung bình đạt được, thể hiện hiệu quả của chính sách.
- **Stability (Standard Deviation):** Độ ổn định của phần thưởng qua các tập huấn luyện.
- **Switching Rate:** Tần suất thay đổi hành động liên tục, dùng để đánh giá tính ổn định của hệ thống mạng.

- **Inference Latency:** Thời gian cần thiết để tác tử đưa ra quyết định khi nhận véc-tơ trạng thái.

5.4.2 Kịch bản thử nghiệm

Hệ thống được kiểm thử qua 4 kịch bản lưu lượng trọng yếu nhằm đánh giá khả năng tổng quát hóa:


1. **Normal traffic:** Lưu lượng mạng bình thường để kiểm tra mức độ can thiệp sai của tác tử.
2. **Sudden attack:** Tấn công DDoS hoặc Port Scan đột ngột với cường độ cao.
3. **Traffic spike:** Lưu lượng tăng đột biến nhưng hợp lệ (không phải tấn công), dùng để kiểm tra tính nhạy cảm của mô hình.
4. **Mixed scenario:** Kịch bản hỗn hợp kết hợp giữa lưu lượng hợp lệ và nhiều dạng tấn công khác nhau diễn ra đồng thời.

Chương 6. KẾT QUẢ VÀ PHÂN TÍCH

Chương này trình bày các kết quả thực nghiệm thu được từ quá trình huấn luyện và đánh giá hiệu năng của các tác tử DQN và PPO so với phương pháp Rule-based truyền thống. Các kết quả được phân tích đa chiều từ khả năng hội tụ, tính ổn định thống kê đến hiệu năng thực thi trong các kịch bản tấn công cụ thể nhằm chứng minh tính hiệu quả của mô hình đề xuất.

6.1 So sánh tổng thể hiệu năng

Để đánh giá khách quan, nhóm thực hiện so sánh phần thưởng trung bình tích lũy của ba phương pháp: DQN, PPO và Rule-based. Dựa trên biểu đồ xếp hạng phần thưởng trung bình tổng thể (*Overall Average Reward Ranking*), các kết quả sơ bộ được ghi nhận như sau:



Hình 6.1. Biểu đồ phân phối phần thưởng của các phương pháp.

- **Tác tử DQN:** Đạt mức phần thưởng trung bình khoảng -2800 . Mặc dù giá trị này cao hơn PPO và Rule-based khi tính trung bình cộng tất cả kịch bản, nhưng qua quan sát chi tiết trên các biểu đồ huấn luyện, DQN không cho thấy sự cải thiện đáng kể về chính sách (*policy*) theo thời gian.

- **Tác tử PPO và Rule-based:** Cả hai phương pháp đều đạt mức phần thưởng quanh ngưỡng -2950 . Sự sụt giảm phần thưởng tổng hợp này chủ yếu do tác động từ các kịch bản tấn công có hình phạt (*penalty*) rất lớn. Tuy nhiên, tác tử PPO thể hiện ưu thế vượt trội và sự ổn định cao hơn hẳn ở kịch bản lưu lượng bình thường (*Normal*).

Việc đánh giá chỉ dựa trên giá trị trung bình tổng hợp có thể dẫn đến các kết luận không chính xác do sự khác biệt đặc thù về cường độ hình phạt giữa kịch bản bình thường và kịch bản tấn công. Vì vậy, các phần tiếp theo sẽ tập trung phân tích sâu vào động lực học của quá trình huấn luyện và hiệu năng thực thi chi tiết theo từng kịch bản riêng biệt.

6.2 Độ ổn định và khả năng hội tụ với huấn luyện Multi-seed

Nhóm nghiên cứu sử dụng phương pháp huấn luyện đa giá trị khởi tạo (*Multi-seed*) với 3 hạt giống cho DQN và 5 hạt giống cho PPO nhằm đảm bảo tính khách quan và khả năng tái lập của kết quả thực nghiệm.


6.2.1 Phân tích đường cong huấn luyện (Learning Curve)

Việc phân tích các chỉ số trong quá trình huấn luyện giúp đánh giá khả năng học tập và tốc độ hội tụ của các tác tử AI.

Dựa trên phân tích các biểu đồ *Mean Reward* (phần thưởng trung bình) và *Training Loss* (hàm mất mát) tại Hình 6.2, xu hướng hội tụ của hai thuật toán được ghi nhận như sau:

- **Thuật toán PPO:** Thể hiện quá trình hội tụ đặc trưng của học tăng cường. Trong giai đoạn đầu, phần thưởng duy trì ở mức âm do RL Agent vẫn đang thực hiện quá trình khám phá môi trường. Từ episode 200, giá trị phần thưởng bắt đầu tăng rõ rệt, vượt ngưỡng 0 tại khoảng episode 500 và dần đạt trạng thái hội tụ ổn định ở mức xấp xỉ $+395$ sau episode 800. Đồng thời, hàm mất mát (*Loss*) cũng giảm dần và ổn định theo thời gian, cho thấy quá trình học diễn ra hiệu quả và nhất quán.

6.2. ĐỘ ỔN ĐỊNH VÀ KHẢ NĂNG HỘI TỤ VỚI HUẤN LUYỆN MULTI-SEED



Hình 6.2. Phân tích hiệu năng huấn luyện của thuật toán DQN và PPO qua đa giá trị khởi tạo.

- **Thuật toán DQN**: Đường cong phần thưởng không cho thấy xu hướng cải thiện rõ rệt, duy trì quanh mức -1450 trong phần lớn quá trình huấn luyện. Kết quả này cho thấy mô hình DQN chưa học được chính sách điều khiển hiệu quả trong môi trường hiện tại. Nguyên nhân có thể xuất phát từ hiện tượng mắc kẹt tại cực trị cục bộ hoặc ảnh hưởng của sai số ước lượng giá trị Q (*overestimation bias*).

6.2.2 Độ ổn định thống kê (Stability)

Để đánh giá độ bền vững và tính nhất quán của mô hình, nhóm nghiên cứu phân tích sự biến động của phần thưởng thông qua độ lệch chuẩn và phân phối xác suất trên các phiên thực nghiệm khác nhau.

- **Độ lệch chuẩn (Standard Deviation)**: Quan sát biểu đồ *Reward Std* trong Hình 6.2 cho thấy một sự tương phản rõ rệt. Sau khi đạt trạng thái hội tụ, độ biến động của tác tử PPO tiệm cận về giá trị 0, minh chứng cho việc thiết lập một chính sách (*policy*) cực kỳ ổn định và đáng tin cậy. Ngược lại, DQN duy

trì mức độ lệch chuẩn cao và dao động liên tục, phản ánh tính không chắc chắn và sự thiếu ổn định trong quá trình ra quyết định của tác tử.


- **Phân phối phần thưởng cuối (*Final Reward Boxplot*):** Dựa trên biểu đồ hộp (Boxplot) so sánh phần thưởng cuối cùng giữa các thuật toán:
 - ◇ **DQN:** Phần thưởng dao động trong khoảng rộng từ -1400 đến -1460 . Sự phân tán này thể hiện tính thiếu nhất quán và hiệu năng không đồng đều giữa các lần huấn luyện khác nhau.
 - ◇ **PPO:** Các điểm dữ liệu tập trung chính xác tại mức $+395$ trên tất cả các giá trị khởi tạo (*seed*). Sự tập trung tuyệt đối này khẳng định tính ổn định vượt trội và độ tin cậy của thuật toán PPO đối với môi trường mạng SDN đang xét.
- **Kiểm định ý nghĩa thống kê:** Để loại bỏ yếu tố ngẫu nhiên, nhóm thực hiện kiểm định T-test giữa hai nhóm kết quả. Với giá trị $p\text{-value} = 3.3 \times 10^{-11}$ (nhỏ hơn rất nhiều so với ngưỡng ý nghĩa $\alpha = 0.001$), kết quả khẳng định sự khác biệt về hiệu năng giữa PPO và DQN là có ý nghĩa thống kê cực kỳ lớn. Điều này cho phép kết luận rằng sự vượt trội của PPO là kết quả của khả năng học tập hiệu quả thay vì do sự may mắn trong quá trình khởi tạo tham số ngẫu nhiên.

6.3 Phân tích tỷ lệ nhảy luật (Switching Rate)

Một chỉ số quan trọng trong vận hành mạng thực tế và tần suất thay đổi hành động liên tục (*Policy Flapping*) được thể hiện qua hình 6.3:

- **DQN:** Có tỷ lệ nhảy luật trung bình khoảng 0.08 qua các kịch bản. Việc thay đổi hành động liên tục có thể gây quá tải cho bảng dòng (flow table) của Switch và Controller.
- **PPO và Rule-based:** Tỷ lệ nhảy luật xấp xỉ bằng 0. Điều này chứng minh PPO đã học được một chính sách xác định (deterministic policy) rất ổn định, giúp giảm thiểu rủi ro vận hành mạng.

6.4. PHÂN TÍCH HIỆU NĂNG THEO KỊCH BẢN



Hình 6.3. Biểu đồ thể hiện tỷ lệ nhảy luật của thuật toán.


6.4 Phân tích hiệu năng theo kịch bản

Nhóm thực hiện đánh giá chi tiết trên 6 kịch bản lưu lượng mạng khác nhau: *normal*, *ddos*, *spoofing*, *overflow*, *packet_in*, và *port_scan*. Kết quả so sánh phần thưởng trung bình giữa các phương pháp được thể hiện chi tiết tại Hình 6.4. Dựa trên dữ liệu thực nghiệm, các quan sát chính bao gồm:

- **Kịch bản Normal:** PPO và Rule-based đạt hiệu quả tối ưu tại mức +395. Điều này chứng minh tác tử PPO đã học được cách duy trì lưu lượng thông suốt mà không kích hoạt các hành động can thiệp sai lệch, đảm bảo chất lượng dịch vụ (QoS) cao nhất.
- **Kịch bản Tấn công (DDoS, Spoofing...):** Tất cả các phương pháp đều ghi nhận mức phần thưởng âm do hệ thống áp dụng hình phạt trực tiếp khi phát hiện các dấu hiệu tấn công mạng.

Để quan sát sự khác biệt cụ thể về mức độ phản ứng của từng mô hình, nhóm sử dụng ma trận nhiệt tại Hình 6.5.

1. **Tác tử DQN:** Có xu hướng nhận ít hình phạt hơn (mức âm thấp hơn) ở một số kịch bản tấn công nhất định. Tuy nhiên, phân tích sâu cho thấy nguyên nhân



Hình 6.4. So sánh phần thưởng trung bình giữa các phương pháp theo từng kịch bản.



Hình 6.5. Ma trận nhiệt thể hiện phân phối phần thưởng theo kịch bản và mô hình.

6.5. NHẬN XÉT CHUNG

xuất phát từ việc tác tử này thực hiện các hành động phòng vệ mang tính bảo thủ (*conservative*), không thực sự tối ưu cho mục tiêu duy trì QoS và bảo mật dài hạn.

2. **PPO so với Rule-based:** Tác tử PPO cho kết quả tương đương với phương pháp Rule-based trên hầu hết các kịch bản. Điều này khẳng định khả năng của Học máy tăng cường trong việc thay thế con người ra quyết định giảm thiểu tấn công một cách tự động mà không cần thiết lập các ngưỡng (*threshold*) thủ công phức tạp.

6.5 Nhận xét chung

Tổng kết kết quả thực nghiệm cho thấy:

- **PPO** là thuật toán phù hợp nhất cho bài toán điều khiển mạng SDN tự động, vượt trội hoàn toàn về khả năng học, độ ổn định thực thi và tính nhất quán trên nhiều điều kiện thử nghiệm khác nhau.
- **DQN** không cho thấy sự hội tụ trong môi trường mạng động, dễ dẫn đến hiện tượng dao động hệ thống và không đảm bảo độ tin cậy để triển khai thực tế.
- Việc PPO đạt hiệu năng tương đương Rule-based ở kịch bản tấn công và ổn định hơn ở kịch bản bình thường đã khẳng định tiềm năng của Học máy tăng cường trong việc tối ưu hóa vận hành và bảo mật mạng thế hệ mới.

Chương 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Sau khi thực hiện đồ án môn học với đề tài “Ứng dụng học máy tăng cường trong ra quyết định điều khiển và giảm thiểu tấn công mạng cho mạng khả lập trình”, nhóm đã đạt được một số kết quả khả quan trong việc ứng dụng AI và học tăng cường vào quá trình tự động hóa bảo mật cho mạng SDN. Hệ thống bước đầu cho thấy khả năng giám sát trạng thái mạng, phát hiện bất thường và đưa ra các hành động phòng thủ phù hợp nhằm giảm thiểu tác động của các cuộc tấn công mạng.

Bên cạnh đó, mô hình cũng đã xây dựng được cơ chế tương tác giữa các tác tử và môi trường mạng theo hướng tự học thông qua hàm thưởng, từ đó giúp hệ thống có khả năng thích nghi với các trạng thái mạng khác nhau và tối ưu hóa quá trình ra quyết định điều khiển.

Mặc dù vậy, để mô hình có thể triển khai thực tế trên quy mô lớn và đảm bảo độ tin cậy cao hơn, hệ thống vẫn cần được bổ sung thêm các cơ chế kiểm thử an toàn, tối ưu hiệu năng và nâng cao khả năng diễn giải quyết định của tác tử học tăng cường nhằm hỗ trợ tốt hơn cho quản trị viên trong quá trình vận hành. Đây sẽ là tiền đề quan trọng cho các nghiên cứu và hướng phát triển tiếp theo của dự án.

7.2 Hạn chế

Hệ thống hiện tại chủ yếu được triển khai và đánh giá trong môi trường mô phỏng nên chưa phản ánh đầy đủ các điều kiện vận hành phức tạp của mạng thực tế. Số lượng kịch bản tấn công mạng và dữ liệu huấn luyện còn giới hạn, do đó khả năng tổng quát hóa của mô hình trước các hình thức tấn công mới (zero-day attacks) vẫn chưa thật sự tối ưu.

Quá trình huấn luyện mô hình Reinforcement Learning tiêu tốn tương đối nhiều thời gian và tài nguyên tính toán, đặc biệt khi mở rộng quy mô mạng hoặc tăng số lượng trạng thái quan sát. Một số tham số của mô hình như learning rate, reward function và epsilon decay vẫn được thiết lập và tinh chỉnh thủ công nên hiệu quả hoạt động chưa thể đạt mức tối ưu hoàn toàn trong mọi kịch bản.

Về mặt thuật toán, hệ thống hiện tại mới chủ yếu dừng ở việc triển khai và so

7.3. HƯỚNG PHÁT TRIỂN

sánh bước đầu giữa hai thuật toán là DQN cơ bản và PPO, chưa thực hiện so sánh sâu với các thuật toán nâng cao khác như A3C, DDPG hay Double/Dueling DQN. Hơn nữa, giống như bản chất của hầu hết các mô hình học sâu, khả năng giải thích quyết định (explainability) của các agent vẫn còn hạn chế. Điều này khiến quản trị viên mạng khó theo dõi và hiểu được nguyên nhân sâu xa phía sau mỗi hành động phòng thủ hoặc định tuyến mà hệ thống tự động đưa ra.

Cuối cùng, hệ thống chưa tích hợp đầy đủ các cơ chế kiểm thử an toàn, dự phòng lỗi và khả năng phục hồi khi xảy ra sự cố. Việc triển khai trên môi trường SDN thực tế với nhiều controller phân tán và thiết bị mạng phần cứng vẫn chưa được thực hiện triệt để do những giới hạn về mặt hạ tầng và tài nguyên nghiên cứu.

7.3 Hướng phát triển

Để hoàn thiện và nâng cao tính ứng dụng thực tiễn của đề tài, nhóm nghiên cứu đề xuất kế hoạch phát triển trong tương lai với hai trọng tâm chính như sau:

7.3.1 Tích hợp công nghệ Digital Twin

Trong tương lai, nhóm nghiên cứu định hướng phát triển hệ thống theo hướng tích hợp công nghệ Digital Twin nhằm xây dựng một môi trường mô phỏng có khả năng phản ánh chính xác trạng thái và kiến trúc của hệ thống mạng thực tế. Mô hình này sẽ đóng vai trò như một lớp kiểm thử trung gian, cho phép triển khai và đánh giá trước các chính sách bảo mật, thuật toán học tăng cường hoặc cơ chế phòng thủ mới trước khi áp dụng lên hệ thống thật.

Việc sử dụng bản sao kỹ thuật Digital Twin giúp giảm thiểu các rủi ro gây ảnh hưởng đến hoạt động của mạng thực, đồng thời hỗ trợ đánh giá hiệu năng, mức độ ổn định và khả năng phản ứng của hệ thống trong nhiều kịch bản tấn công khác nhau. Đây sẽ là nền tảng quan trọng để nâng cao độ tin cậy và khả năng triển khai thực tế của mô hình bảo mật SDN trong tương lai.

7.3.2 Tích hợp LLM hỗ trợ quản trị

Bên cạnh việc nâng cao khả năng phòng thủ tự động, nhóm nghiên cứu cũng hướng đến việc tích hợp các Mô hình Ngôn ngữ Lớn LLM nhằm hỗ trợ quản trị và giám sát

hệ thống mạng hiệu quả hơn. LLM sẽ có nhiệm vụ thu thập, phân tích và tổng hợp các thông tin, sự kiện an ninh mạng từ môi trường SDN để hỗ trợ quá trình theo dõi và đánh giá hệ thống.

Ngoài ra, LLM còn đóng vai trò như một trợ lý ảo giúp diễn giải các quyết định xử lý và hành động phòng thủ của hệ thống AI dưới dạng ngôn ngữ tự nhiên. Điều này giúp quản trị viên dễ dàng hiểu được nguyên nhân và cơ chế hoạt động phía sau các quyết định của mô hình học máy mà không cần trực tiếp phân tích các log dữ liệu phức tạp. Qua đó, hệ thống không chỉ tăng cường tính tự động hóa mà còn cải thiện khả năng tương tác giữa con người và trí tuệ nhân tạo trong quá trình vận hành mạng.

TÀI LIỆU THAM KHẢO

- [1] Shurok Khozam, Gregory Blanc, Sébastien Tixeul, và Eric Totel. “QoSentry: A Reinforcement Learning Framework for QoS-Preserving DDoS Mitigation in Software-Defined Networks”. In: *Journal of Network and Systems Management* 33.4 (2025), p. 97.
- [2] Shurok Khozam, Gregory Blanc, Sebastien Tixeul, và Eric Totel. “DAMS: Double Deep Q-Network Approach for DDoS Attack Mitigation in SDN”. In: *Proceedings of the 8th International Conference on Future Networks & Distributed Systems*. 2024, pp. 1049–1056.
- [3] Nadia Niknami và Jie Wu. “Deepidps: An adaptive drl-based intrusion detection and prevention system for sdn”. In: *ICC 2024-IEEE International Conference on Communications*. IEEE. 2024, pp. 2040–2046.
- [4] Trung V Phan, Syed Tasnimul Islam, Tri Gia Nguyen, và Thomas Bauschert. “Q-DATA: Enhanced traffic flow monitoring in software-defined networks applying Q-learning”. In: *2019 15th International Conference on Network and Service Management (CNSM)*. IEEE. 2019, pp. 1–9.
- [5] Yuanhao He, Geyang Xiao, Jun Zhu, Tao Zou, và Yuan Liang. “Reinforcement learning-based SDN routing scheme empowered by causality detection and GNN”. In: *Frontiers in Computational Neuroscience* 18 (2024), p. 1393025.
- [6] Bao Pham-Thai, My Nguyen-Le-Ha, Luan Van-Thien, Thuat Nguyen-Khanh, và Quan Le-Trung. “DDoS Attack Detection for Software-Defined Network Architecture Based on Artificial Intelligence”. In: *2025 10th IEEE International Conference on Integrated Circuits, Design, and Verification (ICDV)*. 2025, pp. 121–126. DOI: [10.1109/ICDV66179.2025.11135066](https://doi.org/10.1109/ICDV66179.2025.11135066).
- [7] Bao Pham-Thai, My Nguyen-Le-Ha, Thuat Nguyen-Khanh, và Quan Le-Trung. “An Approach to Attack Classification for Programmable Network Infrastructure Using Machine Learning and Deep Learning Solutions”. In: *IEEE Access* 14 (2026), pp. 4886–4916. DOI: [10.1109/ACCESS.2025.3650705](https://doi.org/10.1109/ACCESS.2025.3650705).

- [8] Jing Chen, Jia Chen, và Hongke Zhang. “DRL-QOR: Deep reinforcement learning-based QoS/QoE-aware adaptive online orchestration in NFV-enabled networks”. In: *IEEE Transactions on Network and Service Management* 18.2 (2021), pp. 1758–1774.
- [9] Hauton Tsang, Mohammad A Salahuddin, Noura Limam, và Raouf Boutaba. “Meta-atmos+: A meta-reinforcement learning framework for threat mitigation in software-defined networks”. In: *2023 IEEE 48th Conference on Local Computer Networks (LCN)*. IEEE. 2023, pp. 1–9.